
Stochastic parrots or cognitive agents? Dissociating behavioral performance and internal statistics in large language models' human-like executive functions

随机鹦鹉还是认知主体?大语言模型执行功能中行为表现与内部统计指标的分离

大语言模型 (Large Language Models, LLMs) 在认知任务上展现出类人表现, 但其计算过程究竟是统计模拟还是真正理解仍是未知。本研究通过执行功能多任务范式, 系统探究大语言模型的行为表现与内部计算机制。整合三个独立数据集 ($N = 954$), 让 GPT-4o 完成涵盖抑制控制、工作记忆和认知灵活性的经典认知任务, 同步提取对数概率参数作为内部计算状态指标, 与人类行为数据和 fMRI 神经活动进行比较。

研究揭示了三个主要发现: (1) 选择性复现——LLMs 成功复现 Stroop 干扰效应和工作记忆负荷效应, 且对数概率参数与行为表现呈现系统性关联, 但在反应抑制和任务转换中未能复现人类的典型模式; (2) 行为-统计指标分离——即使在行为相似的任务中, LLMs 统计处理参数显示系统性差异, 如转换任务中零行为代价伴随统计处理复杂度 (困惑度) 显著增加 ($d = 1.07, p < 0.001$); (3) 神经映射特异性——仅在 N -back 工作记忆任务中发现 LLMs 与人脑激活模式的统计学对应关系 ($r = 0.259, p < 0.001$), 其他执行功能子成分无此关联。

初步研究结果提示, 对数概率参数与执行功能任务表现存在系统性关联, 表明这些统计指标能够一定程度上反映 LLMs 处理不同认知任务时的计算复杂度差异。大语言模型可能采用了与人类不同的计算策略来实现表面相似的认知表现, 呈现出行为表现与统计处理模式的分离特征。研究发现提示基于行为表现评估人工智能的传统范式可能存在局限性, 建议未来建立整合内部统计分析的新评估体系。

28 关键词：大语言模型；人工智能；执行功能；随机鹦鹉；对数概率参数

29

30 1 引言

31 大语言模型 (Large Language Models, LLMs) 作为当代人工智能 (Artificial
32 Intelligence, AI) 的重要技术成果, 已远超语言处理本身, 在数学推理、代码生
33 成、视觉理解等非语言领域都表现出惊人的泛化能力 (Hutson, 2024)。这一现象
34 引发了认知科学的核心问题: 基于 *Transformer* 架构¹的语言模型在非语言任务上
35 的泛化表现, 究竟体现了某种形式的认知能力, 还是仅仅反映了大规模参数训练
36 下的统计模式匹配? 这个问题推动着研究焦点从单纯的语言处理转向对 AI 认知
37 机制的系统性探索。近年来, 研究者开始关注大语言模型在意识 (Du et al., 2025)、
38 决策处理 (Hagendorff et al., 2023; Suri et al., 2024)、道德判断 (Agarwal et al.,
39 2024)、心理理论 (Kosinski, 2024) 和创造性思维 (Chen & Ding, 2023) 等高级
40 认知功能上的表现。这种研究转向的核心在于理解大语言模型是否具有类人的认
41 知机制 (Binz et al., 2025; Chemero, 2023; Frank, 2023)。

42 事实上, 关于人工智能是否具有真正理解能力的争论贯穿了 AI 发展的整个
43 历史。从 Turing (1950) 提出通过行为表现判定机器智能的图灵测试 (The Turing
44 Test), 到 Searle (1980) 通过中文屋 (Chinese room) 论证揭示符号操作与语义
45 理解之间的鸿沟, 再到 Bender 等人 (2021) 提出的"随机鹦鹉" (Stochastic Parrots)
46 假说——认为即使最先进的大语言模型仍只是在重现训练数据中的统计规律, 本
47 质上是模式匹配系统, 缺乏真正的理解和推理能力。如今, 当大语言模型在各种
48 认知加工任务上接近甚至超越人类表现时 (Binz & Schulz, 2023; Lamprinidis,
49 2023), 这个根本问题变得更加关键: 当 AI 系统在行为上越来越接近人类时, 我
50 们如何判断它们是否具有真正的认知理解? 这对于重塑我们对智能本质的认识
51 具有重要意义。

52 传统认知科学假设行为表现与底层机制存在系统性对应关系 (Marr & Vaina,
53 1982)——相似的行为表现通常意味着相似的认知机制。然而, 这一假设在评估

¹ Transformer 是由 Google 研究团队于 2017 年提出的深度学习架构, 其核心创新是通过自注意力机制替代传统循环神经网络, 显著提升了自然语言处理任务的性能 (Vaswani et al., 2017)。这一最初为机器翻译设计的架构, 如今成为了通用人工智能模型发展的技术基础。

54 人工智能系统时面临根本挑战。近期研究发现,大语言模型能够在多种认知任务
55 上复现人类的行为模式,包括决策偏差 (Binz & Schulz, 2023b)、抽象推理 (Webb
56 et al., 2023),甚至社会认知 (Kosinski, 2024)。这些发现引发了一个关键问题:行
57 为层面的相似是否必然意味着认知机制的等价?有研究发现,大语言模型在单独
58 测试时往往能够展现这些能力,但却无法可靠地整合和部署这些能力来服务于目
59 标 (Webb et al., 2023)。这揭示了 AI 认知的一个重要特征——功能分离但整合困
60 难。模型可能通过识别训练数据中的相似模式来完成测试任务,而无需理解任务
61 的认知要求。大语言模型在某些简单任务上的系统性失败进一步表明其认知架构
62 与人类存在根本差异 (Lamprinidis, 2023)。因此,仅凭行为表现已不足以判断 AI
63 是否具有真正的理解,需要进一步探究其内部计算过程或表征状态。

64 执行功能 (Executive functions, EFs) 为检验大语言模型的认知理解提供了
65 理想的测试框架。作为支撑人类灵活目标导向行为的领域通用认知系统,执行功
66 能包含三个核心成分:抑制控制、工作记忆刷新和认知灵活性 (Diamond, 2013;
67 Miyake et al., 2000)。这些成分不仅是人类高级认知的基础,也最近被认为是未来
68 发展通用人工智能的必要条件 (Goyal & Bengio, 2022)。从神经基础看,人类的
69 执行功能通过前额叶皮层中专门化模块的协调互动实现,而非依赖单一整体系统。
70 前额叶-顶叶网络,包括背外侧前额叶、前扣带皮层和后顶叶皮层,构成了执行
71 控制的核心回路 (Niendam et al., 2012)。这些区域通过动态协调实现自上而下的
72 控制,其激活模式为评估 AI 系统是否实现类似计算提供了神经标准。这一神经
73 组织原则提示我们:理解大语言模型的认知能力需要考虑其可能采用了与人脑模
74 块化组织不同的计算架构。此外,选择执行功能作为研究焦点具有一定方法论优
75 势。具体来说,执行功能的计算挑战具有普遍性——无论是生物还是人工系统,
76 都需要解决注意分配、信息更新和冲突解决等基本问题。其次,执行功能的多成
77 分结构允许系统性比较:如果大语言模型仅是通过表面模式匹配来"解决"任务,
78 其在不同执行功能成分上的表现应该缺乏内在一致性。第三,执行功能任务中的
79 "任务不纯度"问题 (task impurity problem) ——即任何单一任务都涉及多个认知
80 成分的交互 (Friedman & Miyake, 2017; Yangüez et al., 2024)——在 AI 研究中转
81 化为独特优势。通过让同一模型完成测量相同认知构念的不同范式,我们可以检


验其是否捕捉到了执行功能的核心计算原理, 还是仅仅记住了特定任务的表面规律。尽管近期研究已开始探索大语言模型的执行功能表现, 但这些研究主要局限在行为比较层面, 很少探索模型的内部计算过程, 也较少将大语言模型的内部计算与人脑认知加工神经机制进行直接比较。

理解 AI 认知机制的关键在于找到合适的内部状态指标。OpenAI 最近开放的 logprobs 参数²为探究模型内部机制提供了新的技术路径。从计算角度看, 这些对数概率参数——包括困惑度、对数概率方差、平均对数概率和最小对数概率——反映了模型在生成响应时面临的统计不确定性和预测复杂度 (Bauer et al., 2025)。虽然 logprobs 本质上是基于词汇概率分布的统计指标, 但其动态变化模式可能为理解模型的内部计算状态提供有价值的线索。类似于神经科学通过记录神经元活动模式来推断认知过程, 我们可以通过分析模型在不同任务条件下的概率分布变化来探究其"计算"状态的特征。最近有研究证实, 人工智能语言模型的内部表征与大脑神经活动模式存在一定的对应关系, 脑活动与语言模型的内部嵌入呈现出线性相关 (Goldstein et al., 2025)。基于这一理论基础, 如果大语言模型在处理认知任务时采用了系统性的计算过程, 其统计处理模式可能会: (1) 随任务认知难度系统性变化; (2) 与行为表现存在预期的关联模式; (3) 在模式特征上与人脑执行功能神经活动呈现统计学意义上的对应关系。


综上所述, 当前对于大语言模型在认知任务上展现出类人表现, 但其计算过程的特征仍有待深入理解。鉴于此, 本研究通过让大语言模型完成具有上下文的人类执行功能多任务范式, 将对数概率参数作为量化模型统计处理复杂度的技术指标。研究将整合三个独立数据集的人类执行功能数据, 系统分析模型的逐试次表现并提取统计处理参数, 与人类行为数据进行比较, 并探究模型表现与统计处理参数以及人脑执行功能神经活动的关联 (见 图 1)。通过探索性地分析模型统计处理模式与行为表现的关联, 以及其与人类认知神经机制的对应程度, 研究有望为理解大语言模型计算特征提供初步实证线索, 对认知科学和人工智能领域的方法论发展提供参考。

² <https://platform.openai.com/docs/api-reference/introduction>


Step 1. Executive Function Assessments from Humans and Large Language Models




Step 2. Bayesian Difference Testing and Logprobs Parameters Correlation Analysis



Step 3. Cross-paradigm Validation



Step 4. Regression and Representational Similarity Analysis between Logprobs Parameters and ROI Activation



108

图 1 实验设计流程图

109 注：研究包括四个主要步骤。步骤一：收集人类被试在执行功能任务中的行为数据（数据集

110 1），同时让大语言模型完成相同任务，提取模型输出的对数概率作为其内部计算状态的量化

指标。步骤二：采用贝叶斯层次分析方法，检验大语言模型能否复现人类在执行功能任务中的经典认知效应，并分析模型行为表现与对数概率参数的关联性。步骤三：比较人类被试（数据集 3）和大语言模型在不同实验范式下完成相同执行功能子成分任务的表现，评估两者跨任务表现的内部一致性。步骤四：提取执行功能相关脑区的激活值（数据集 2，感兴趣区域 ROI 分析），通过岭回归和表征相似性分析，探索大语言模型的对数概率参数与人类大脑神经活动模式之间的对应关系。

2 方法

2.1 被试

本研究通过整合三个独立数据集进行分析（见 表 1）。三个数据集的参与者均来自中国不同地区的高等院校，在教育背景、年龄分布等人口学特征方面具有较好的一致性，这种匹配性为跨数据集的比较分析提供了有效基础。三个数据集的整合使用得到了各原始研究团队的授权许可，数据处理过程中严格遵守了数据保护和隐私保护的相关规定。

数据集 1 包括 45 名汉语母语者的执行功能行为测量数据。参与者均为成年人，平均年龄 20.84 岁（标准差 2.13 岁），其中男性 19 名（占 42.2%），女性 26 名（占 57.8%）。所有参与者完成了五项标准化认知任务，这些任务用于系统地评估执行功能的核心成分。参与者的纳入标准包括：以汉语为母语，具有正常视力或矫正后视力正常，无色盲或色弱状况。排除标准为：存在神经系统疾病史、精神疾病史或药物滥用史，以及正在服用可能影响认知功能药物的个体。所有参与者在实验前均签署了知情同意书，实验程序符合相关伦理委员会的审批要求。本研究已获得西北师范大学伦理委员会批准。

数据集 2 采用 He 等人（2021）研究中的功能磁共振成像数据，包含 39 名右利手本科生，其中男性 13 名，女性 26 名，平均年龄 19.21 岁（标准差 0.52 岁）。参与者在磁共振扫描环境下完成了三项执行功能任务。所有参与者均通过了 MRI 安全筛查，确认无磁共振扫描禁忌症，并在实验前签署了知情同意书。该数据集的 fMRI 扫描参数和具体任务程序遵循 He 等人（2021）的原始研究设计。

数据集 3 来源于 Feng 等人（2022）开展的汉族青年认知神经遗传学研究项

目 (Cognitive Neurogenetic Study of Han Chinese Young Adults, CNSCYA), 包含 870 名参与者的行为测量数据, 其中男性 349 名, 女性 521 名, 平均年龄 20.96 岁 (标准差 1.87 岁)。该数据集涵盖了九项执行功能任务的测量结果, 这些任务采用了不同的实验范式, 为本研究的跨任务验证提供了重要基础。参与者的招募和测试程序遵循 Feng 等人 (2022) 报告的标准化流程。

表 1 三个数据集被试人口学信息

	数据集 1 (N=45)	数据集 2 (N=39)	数据集 3 (N=870)
年龄	20.84 ± 2.13	19.21 ± 0.52	20.96 ± 1.87
性别			
男	19 (42.2%)	13 (33.3%)	349 (40.1%)
女	26 (57.8%)	26 (66.7%)	521 (59.9%)
执行功能测量 任务范式	Stroop 色词任务		反向眼跳任务
	Go/No-Go 任务	n-back 任务	停止信号任务
	数字转换任务	停止信号任务	Stroop 色词任务
	活动记忆任务	数字-字母类别转换任务	保持追踪任务
	数字正背和倒背任务		字母 3-back 任务
			空间 2-back 任务
			数字-字母转换任务
			颜色-形状转换任务
			类别转换任务
数据采集地区	中国 兰州	中国 重庆	中国 北京和重庆


147

2.2 执行功能测量与研究程序

认知心理学研究中, 同一认知成分通常可通过多个实验范式进行测量 (Yangüez et al., 2024)。本研究采用多种经典范式以确保测量的稳定性和有效性。所有测试在标准化的计算机实验室中进行, 实验设备配置如下: 15.6 英寸 LED 显示器, 分辨率 1600×900 像素, 刷新率 60Hz, 参与者眼睛与屏幕保持 60cm 的标准距离。实验程序使用 E-Prime 2.0 软件 (Psychology Software Tools, Pittsburgh,

154 PA) 编程。所有测试均由经过专门培训的心理学研究生按照标准化流程实施,
155 以确保不同批次数据采集的一致性。

156



157 图 2 执行功能范式流程图

158 注: 本图为研究中使用的执行功能测量任务的实验流程。所有任务均记录参与者的
159 的按键反应数据。橙色标注为数据集 1 中的任务, 绿色标注为数据集 2 中的任务,
160 蓝色标注为数据集 3 中的任务。

161

162 2.2.数据集 1 执行功能测量任务

163 (1) 基于 *Stroop* 色词任务测量干扰抑制能力

164 本研究采用计算机化版本的 *Stroop* 色词任务评估参与者的干扰抑制能力
165 (*Stroop*, 1935)。实验材料包括两个高频汉字颜色词 ("红"、"绿") 以及中性刺激
166 ("#####") (见 图 2)。所有刺激以红色或绿色呈现于屏幕中央, 视角约为 $2.5^{\circ} \times 1.5^{\circ}$ 。
167 参与者的任务是忽略字义信息的干扰, 仅根据刺激的颜色进行按键反应: 看到红
168 色刺激按"F"键 (左手食指), 看到绿色刺激按"J"键 (右手食指)。任务包含三种

实验条件：(1) 一致条件：字义与颜色匹配（如红色呈现的“红”字）；(2) 不一致条件：字义与颜色冲突（如红色呈现的“绿”字）；(3) 中性条件：无语义信息的颜色刺激（如红色呈现的“#####”）。不一致条件与一致条件的反应时差值即为 Stroop 干扰效应，该指标反映了个体的干扰抑制能力。实验程序采用事件相关设计。每个试次按照以下时序呈现：注视点“+”（500ms）→ 空屏（1000ms）→ 目标刺激（1500ms 或直至参与者做出反应）→ 试次间隔（500ms）。实验包含 1 个练习模块（18 试次，提供正确/错误的即时反馈）和 3 个正式测试模块（每模块 36 试次：一致、不一致、中性条件各 12 试次），共计 108 个正式试次。三种条件以伪随机顺序呈现，确保同一条件不会连续出现超过 3 次。参与者需要在练习阶段达到 85% 的正确率才能进入正式测试。模块之间设置自定步调的休息时间，整个任务持续约 15 分钟。

(2) 基于 *Go/No-Go* 任务测量反应抑制能力

反应抑制能力通过经典的 Go/No-Go 范式进行评估 (Gomez et al., 2007)。任务采用简单的字母刺激 (“X”和“Y”)，以控制语义加工可能带来的混淆。参与者需要对 Go 刺激（目标字母）快速按键反应，对 No-Go 刺激（非目标字母）抑制反应冲动。实验流程如下：注视点“+”（1000ms）→ 目标刺激（600ms）→ 空屏反应窗口（400ms）→ 试次间隔（500ms）。相对较短的刺激呈现时间（600ms）旨在增加任务难度，诱发更强的预备反应倾向，从而更敏感地测量抑制控制能力。实验设计采用目标平衡设计以控制刺激特异性效应。正式测试包含 4 个模块（每模块 100 试次：50 个 Go 试次，50 个 No-Go 试次），共 400 试次。其中，模块 1 和 3 定义 X 为 Go 刺激、Y 为 No-Go 刺激；模块 2 和 4 则相反。模块顺序在参与者间进行拉丁方平衡。正式测试前设置 20 试次练习（提供即时反馈），要求达到 85% 正确率。主要因变量包括：Go 试次反应时、Go 试次正确率以及 No-Go 试次正确率。任务总时长约 15 分钟。

(3) 基于数字转换任务测量认知灵活性

本研究采用数字转换任务测量认知灵活性中的转换能力 (Kray et al., 2002)。任务由两个子任务组成：任务 A（大小判断任务）和任务 B（奇偶判断任务）。

任务 A 的刺激材料为红色数字 (1-9, 除 5 外), 要求参与者判断数字的大小: 若数字小于 5, 按"A"键; 若大于 5, 按"L"键。任务 B 的刺激材料为蓝色数字 (1-9, 除 5 外), 要求参与者判断数字的奇偶性: 若为奇数, 按"A"键; 若为偶数, 按"L"键。实验共包含 20 个组块, 分别为 10 个单一任务组块和 10 个混合任务组块。每个单一任务组块包含 8 个试次, 每个混合任务组块包含 17 个试次, 整个实验共 250 个试次。组块按照两个单一任务组块和两个混合任务组块的组合顺序随机呈现。正式实验前设有 2 个单一任务练习组块, 让参与者熟悉实验规则, 练习正确率达到 75%后才可进入正式实验。参与者阅读指导语后, 按 Q 键进入实验程序。每个组块开始前在屏幕中央呈现黑色注视点"+", 接着刺激呈现, 直到参与者做出反应, 25ms 之后进入下一个试次。整个任务持续约 15 分钟。转换代价通过比较混合组块中转换试次与重复试次的反应时差值来计算。

(4) 基于活动记忆任务测量工作记忆刷新能力

研究采用数字刷新任务 (Running memory task) 考察参与者工作记忆中的刷新能力 (Wang et al., 2025)。任务分为简单和困难两种条件, 简单任务中数字呈现时间为 1750ms, 困难任务中为 750ms。参与者先完成简单任务, 再进行困难任务。在任务中, 屏幕上随机呈现 0-9 的数字系列, 包括长度为 5、7、9 和 11 的四种序列。要求参与者不断复述出现的数字并按顺序记住最后 3 个数字。例如, 当屏幕依次出现 6、8、5、4、7、2 时, 参与者需要记住的序列为: 6-68-685-854-547-472, 并在屏幕的黑色框内输入最后 3 个数字 (4、7、2), 按空格键进入下一系列。简单任务包括 1 个练习模块和 2 个正式实验模块。练习模块包含 8 个试次, 每种长度随机出现 2 次。正式实验的每个模块包含 12 个试次, 每个数字长度随机出现 3 次。困难任务共 2 个模块, 每个包含 12 个试次, 每个数字长度随机出现 3 次。简单刷新任务和困难刷新任务的平均正确率作为刷新能力指标。整个任务约需 20 分钟, 参与者可在每个模块间进行休息。

(5) 基于数字正背和倒背任务测量工作记忆广度

参照韦氏智力测验中的数字广度测验, 我们采用数字正背和数字倒背任务来评估参与者的工作记忆广度能力。在数字正背任务中, 首先给参与者随机呈现

0-9 的一系列数字 (每个数字呈现 1000ms), 参与者需要按照看到的顺序将数字依次输入屏幕中央的方框。如参与者看到 1-2-3, 则需要输入 1-2-3。实验任务难度从记忆 3 个数字开始, 每个难度有 3 次机会。若参与者回答正确两个试次及以上, 记忆项目增加 1; 否则, 任务结束。在倒背任务中, 仍是给参与者随机呈现 0-9 的一系列数字 (每个数字呈现 1000ms), 参与者需要将看到的数字按相反的顺序依次输入屏幕中央的方框。如参与者看到 1-2-3, 则需要输入 3-2-1。实验任务难度从记忆 3 个数字开始, 每个难度有 3 次机会。若参与者回答正确两个试次及以上, 记忆项目增加 1; 否则, 任务结束。这两个任务的指标均为参与者的最大记忆广度。两项任务的实施顺序在参与者间进行了平衡。

2.2.2 数据集 2 执行功能测量任务

参与者在不同日期按照 n-back 任务、停止信号任务和数字-字母类别转换任务的顺序完成执行功能任务 (见 图 2)。所有参与者在扫描前都完成了相应的练习环节, 以理解刺激-反应关联和任务规则。(1) n-Back 任务: 数字 n-back 任务包含三种条件 (0-back、1-back 和 2-back), 以组块设计呈现。在 0-back 条件中, 参与者需要检测屏幕上当前项目是否为"1"。在 1-back 和 2-back 任务中, 参与者需要检测当前项目是否在序列中的前一次或前两次出现过。参与者在检测到目标时需要按键反应。每种条件有四个组块, 每个 29 秒的组块包括 2 秒的任务提示, 然后是 15 个连续的单数字刺激试次 (持续 400 毫秒, 刺激间间隔 1400 毫秒), 参与者有 1400 毫秒的时间窗口对目标刺激做出反应。组块间有 6 秒间隔。三个任务以伪随机顺序呈现, 连续重复不超过三次。(2) 停止信号任务: 停止信号任务包括 32 个停止试次和 96 个执行试次。每个试次开始时有 300 毫秒的中央注视十字, 然后屏幕上显示指向左或右的绿色箭头。对于执行试次, 绿色箭头持续 500 毫秒。参与者需要在 1500 毫秒内尽可能快速准确地按"1" (左箭头) 或"2" (右箭头) 键, 然后是持续 700 毫秒的空白屏幕。对于停止试次, 有停止信号延迟 (SSD), 根据参与者的反应动态调整, 作为绿色箭头的持续时间, 然后停止信号 (红色箭头) 出现 300 毫秒。参与者需要抑制已经启动的反应。初始 SSD 值为 250 毫秒。如果参与者在停止试次中成功抑制, 则在后续停止试次中增加 50 毫秒 SSD 使抑制更困难; 如果参与者未成功抑制, 则减少 50 毫秒 SSD 使抑

制更容易。然后显示空白屏幕，持续时间为 1200 毫秒减去 SSD。试次间还有 1-4 秒的抖动（平均=2.5 秒）。(3) 数字-字母类别转换任务：转换任务包括 48 个重复试次和 48 个转换试次。每个试次开始时有 1000 毫秒的中央注视十字，然后呈现数字-字母或字母-数字对 2500 毫秒。当字母为红色时，参与者需要判断数字是奇数还是偶数；当字母为绿色时，判断字母是辅音还是元音。参与者在刺激出现后 2500 毫秒内尽可能快速准确地按"1"（奇数和辅音）或"2"（偶数和元音）键。试次间间隔为 1-4 秒（平均=2.5 秒）。如果当前试次的判断类型与前一试次相同，则定义为重复试次（第一个试次之后），否则为转换试次。两种条件以伪随机顺序呈现，重复不超过四次，重复反应也不超过四次。

2.2.3 数据集 3 执行功能测量任务

数据集 3 包含九项执行功能任务，全面评估执行功能三成分（Feng et al., 2022）。**i. 抑制成分任务：**（1）反向眼跳任务：每试次先呈现中央注视点"+"（1500-3500ms 随机），然后在屏幕一侧呈现视觉线索（0.32cm 黑色方块，150ms），目标（包含箭头的 1.11cm 方块）出现在屏幕另一侧，175ms 后变灰。参与者需控制注意指向目标而非线索，判断箭头方向。包含 22 个练习试次和 90 个测试试次。指标为错误率。（2）停止信号任务：与数据集 2 类似，采用阶梯追踪程序动态调整停止信号延迟时间。指标为停止信号反应时间（SSRT）。（3）色词 Stroop 任务：使用中文颜色词（红、绿、黄、蓝），包含一致和不一致条件各 48 试次，共 96 试次。指标为干扰效应（不一致条件与一致条件的反应时差）。**ii. 工作记忆刷新成分任务：**（4）保持追踪任务：屏幕底部呈现 2-4 个目标类别（动物、国家、颜色、金属、距离、亲属），中央逐个呈现 15 个词（每词 1500ms）。参与者需记住每个类别最后出现的词。包含 12 个词表（4 个 2 类别、4 个 3 类别、4 个 4 类别）。指标为正确回忆词数。（5）字母 3-back 任务：连续呈现 13 个字母序列，每个字母呈现 750ms，后接 2250ms 空屏。参与者判断当前字母是否与 3 个位置前相同。包含 6 个组块，每组块 15 试次。指标为 d' （区分敏感性指标）。（6）空间 2-back 任务：屏幕上 10 个方块依次闪烁（每个 500ms，间隔 1500ms），参与者判断当前方块是否与 2 个位置前相同。包含 3 个组块，每组块 24 试次。指标为 d' 。**iii. 转换成分任务：**（7）数字-字母转换任务：包含 160 试次。数字-字母对

出现在屏幕上方时判断数字奇偶性, 出现在下方时判断字母是否为元音。指标为转换代价 (转换试次与重复试次的反应时差值)。(8) 颜色-形状转换任务: 包含 160 试次。根据线索 ("YS"表示颜色, "XZ"表示形状) 判断红/绿色圆形/三角形的颜色或形状。线索呈现 150ms 后出现刺激。指标为转换代价。(9) 类别转换任务: 包含 96 试次。根据线索 ("生命性"或"大小") 判断词语是生物/非生物或比鞋盒大/小。线索呈现 150ms 后出现词语, 最长呈现 3 秒。指标为转换代价。

2.3 神经影像数据采集与处理

2.3.1 数据采集

神经影像数据采集的详细程序参照 He 等人 (2021) 的研究方案。所有磁共振成像数据均在西南大学脑成像中心获取, 使用配备 12 通道头部线圈的西门子 3T Trio 磁共振扫描仪 (Siemens Medical Systems, Erlangen, Germany)。功能磁共振成像采用回声平面成像 (EPI) 序列, 具体参数设置为: 重复时间 (TR) = 2000ms, 回声时间 (TE) = 30ms, 扫描层数 = 32, 层间距 = 1mm, 翻转角 = 90°, 视野 (FOV) = 220×220mm², 层厚 = 3mm, 体素分辨率 = 3.4×3.4×3mm³。结构成像采用磁化预备快速梯度回声 (MPRAGE) 序列获取高分辨率 T1 加权图像, 参数设置为: TR = 2530ms, TE = 3.45ms, 扫描层数 = 192, 翻转角 = 7°, FOV = 256×256mm², 层厚 = 1mm, 体素分辨率 = 1×1×1mm³。扫描过程中使用泡沫垫固定参与者头部以减少头动, 并通过耳塞降低扫描噪音对参与者的影响。

2.3.2 fMRI 数据预处理

功能影像数据预处理采用 DPABI 工具包结合 SPM12 软件 (<http://www.fil.ion.ucl.ac.uk/spm>) 在 MATLAB 平台上实施 (Yan et al., 2016)。预处理遵循标准化流程: (1) 进行时间层校正以消除层间采集时间差异, 并实施头动校正以矫正扫描过程中的头部微小移动, 排除头动超过 3mm 或旋转超过 3° 的数据; (2) 将个体结构像配准到平均功能像以建立结构-功能对应关系; (3) 采用 DARTEL 算法将结构像精确分割为灰质、白质和脑脊液三种组织类型; (4) 基于分割得到的形变参数, 将功能像标准化到蒙特利尔神经研究所 (MNI) 标准

空间，并重采样至 $3\times3\times3\text{mm}^3$ 体素大小；(5) 应用 8mm 全宽半高 (FWHM) 的高斯核进行空间平滑，以提高信噪比并满足统计分析的空间连续性假设。

2.3.3 任务激活的统计建模

研究采用 SPM12 软件进行基于体素的单变量激活分析。在个体水平分析中，为每个被试构建一般线性模型 (GLM) 以估计各实验条件的激活强度。对于 n-back 工作记忆任务，模型包含 0-back、1-back、2-back 三个任务条件以及基线条件；停止信号任务包含成功执行试次、成功停止试次、基线条件以及错误试次；任务转换范式则包含成功转换试次、成功重复试次、基线条件，以及其他试次类型 (包括首试次、错误试次和错误后试次)。为控制头动相关的伪影，将六个刚体运动参数作为协变量纳入模型。所有任务条件的时间序列均与标准血流动力学响应函数进行卷积，并应用截止频率为 1/128Hz 的高通滤波器以去除低频信号漂移。在此基础上设定关键实验对比：n-back 任务采用 "2-back > 0-back" 对比以反映工作记忆负荷效应；停止信号任务采用 "成功停止 > 成功执行" 对比以捕获抑制控制过程；任务转换范式采用 "成功转换 > 成功重复" 对比以量化认知灵活性成本。个体水平的对比图像随后进入组水平随机效应分析，采用基于团簇水平的家族误差校正 (cluster-level FWE correction, $p < 0.05$) 进行多重比较校正，最小团簇大小设定为 10 个体素。统计推断使用 Python 的 Nilearn 工具包 (<https://nilearn.github.io>) 实施 (Abraham et al., 2014)。

2.4 大模型问答流程

本研究通过 OpenAI 官方商用 API 形式调用 OpenAI GPT-4o ("Omnimodel") -2024-05-13 模型 (<https://platform.openai.com/docs/models>)，该模型被认为是大语言模型技术在人机交互领域的重要进展，具备优异的多模态理解和复杂推理能力。为避免数据污染问题，确保所测试的大语言模型在训练期间未接触过本研究的任务材料，研究仅选择训练数据收集时间早于任务发布日期的模型进行测试。为最大化结果的可重复性，将 temperature 参数设置为最小值 (temperature = 0)，其他参数均采用默认配置 (Coda-Forno et al., 2024; Kosinski, 2024; Suri et al., 2024)。每个模拟被试的测试在相同的系统提示词下进行，确保初始条件的一致

性。

本研究通过提示词驱动的多轮对话范式开展实验，模拟 30 名独立的"AI 被试"完成执行功能任务。为确保实验的生态效度和内部一致性，所有执行功能任务均在完整的单一对话上下文中完成，保证各模拟被试间的独立性。在具体实施中，研究采用了连续对话策略：每个模拟被试的所有试次在同一个对话会话中依次完成，新的试次以用户消息形式追加到对话历史中，模型回答以助手消息形式记录，使后续试次能够访问之前的所有交互记录。这种设计使模型能够在实验过程中维持一致的"被试身份"，并表现出类似人类的学习效应和反应模式 (Coda-Forno et al., 2024; Gong et al., 2024; Hu & Lewis, 2024; Kosinski, 2024; Suri et al., 2024)。为进一步分析模型的认知过程，实验过程中同步记录了模型输出的每个 token 的对数概率参数 (见 表 2)。Chat Completions API³中的 *logprobs* 参数能够提供每个输出 token 的对数概率，以及每个 token 位置上最可能的有限数量 token 及其对数概率，这在评估模型输出置信度或检查模型可能给出的替代回答时具有重要价值 (Bauer et al., 2025)。这些参数可以类比为人类认知过程中的反应时和置信度指标，为理解模型的"认知负荷"提供了量化依据。

表 2 对数概率参数说明

参数名称	含义	计算方式	高数值意味着	认知类比
Perplexity	困惑度：模型对序列的"惊讶程度"或不确定性	$2^{(-\text{平均对数概率})}$	模型很困惑，不确定答案	人类面对难题时的"纠结程度"
Logprob Variance	对数概率方差：模型在不同词元各词元对数概率的选择上的一致性	方差	选择时摇摆不定，不一致	思考时的"稳定性"
Avg Logprob	平均对数概率：模型对整个序列所有词元对数概率的平均置信度	均值	整体置信度高	对答案的"总体信心"
Min Logprob	最小对数概率：序列中最不确定所有词元中最小的对存在高度不确定的那个词元	数概率	择	选答案中"最薄弱的环节"

注：对数概率参数通过 OpenAI API 获取 (<https://platform.openai.com/docs/api-reference/chat/create>)，反映大语言模型在执行任务时的不确定性、困惑度和决策置信度，可类比为人类认知过程中的神经活动指标。这些参数为理解 AI 系统的"认知"过程提供了可量化的行为指标。

3 https://github.com/openai/openai-cookbook/blob/main/examples/Using_logprobs.ipynb

2.5 问答后的分析

2.5.1 大语言模型与人类执行功能对比分析

为探究大语言模型是否能够复现人类在执行功能任务中的经典认知效应, 本研究采用贝叶斯层次方差分析 (Bayesian hierarchical ANOVA) 进行系统比较 (Veenman et al., 2024)。分析模型以任务表现指标 (反应时或正确率) 为因变量, 包含组别 (AI vs Human) 和条件 (如一致 vs 不一致) 两个固定效应, 以及组别 $\times$ 条件的交互项。同时设置被试作为随机截距以控制个体差异 (见 公式 1):

$$Y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + u_k + \epsilon_{ijk} \quad \text{公式 1}$$

其中, Y_{ijk} 为任务表现指标, α_i 为组别效应, β_j 为条件效应, $(\alpha\beta)_{ij}$ 为交互效应, u_k 为被试 k 的随机截距, ϵ_{ijk} 为残差项

在贝叶斯推断框架下, 首先分别估计 AI 与人类各项认知效应的后验分布, 计算其方向一致性概率 $P(\text{同方向})$ 及对应的贝叶斯因子 (Bayes Factor, BF), 用于评估质的相似性 (即效应模式是否一致)。随后估计两组认知效应的差值 $\Delta = \text{Effect}_{\text{LLM}} - \text{Effect}_{\text{Human}}$, 并计算差值落在等价区间内的概率以及等价性贝叶斯因子, 用于评估量的相似性 (即效应大小是否等价)。所有模型均采用 No-U-Turn Sampler (NUTS) 进行马尔可夫链蒙特卡罗 (MCMC) 采样, 每条链包含 1000 次热身迭代和 2000 次正式采样, 使用两条链并行计算以确保收敛性 ($\hat{R} < 1.01$)。分析在 Python 环境下使用 PyMC 包实现 (<https://www.pymc.io/welcome.html>)。

为进一步探究人类与 AI 在执行功能各子成分上的相似程度, 本研究构建了基于标准化行为指标的机器学习分类器。采用随机森林 (Random Forest) 进行交叉验证, 确保结果的稳健性。通过逐一移除各执行功能变量的消融分析, 识别对分类准确率影响较小的成分, 这些成分可能反映了人类与 AI 表现相似的认知过程 (Miller et al., 2023)。此外, 为揭示大语言模型内部计算机制与外显行为的关

375 联，本研究对模型的任务表现与对数概率参数进行皮尔逊相关分析。具体分析了
376 各执行功能任务的行为指标（反应时或正确率）与四类对数概率参数（困惑度、
377 对数概率方差、平均对数概率、最小对数概率）之间的线性关系。为控制多重比
378 较带来的 I 类错误，采用 Benjamini-Hochberg 方法对所有相关系数进行 FDR 校
379 正 ($\alpha = 0.05$) (Benjamini et al., 2001)。各执行功能效应的具体计算方法见表 3。
380

381 表 3 执行功能效应计算

Executive Function Effect	Calculation Method	Reference
Stroop Interference Effect	RT Incongruent - RT Congruent	MacLeod (1991)
Go/No-go Inhibition Effect	Accuracy NoGo - Accuracy Go	Criaud & Boulinguez (2013)
Stop Signal Inhibition Effect	Stop Signal Reaction Time (SSRT)	Logan et al. (1984)
Task Switching Cost	RT Switch - RT Repeat	Schwarze et al. (2025)
	Accuracy 750ms - Accuracy 1750ms	
Working Memory Updating	Accuracy 2back - Accuracy 0back	Wang et al. (2025)
Load Effect	Accuracy 2back - Accuracy 1back	
	Accuracy 1back - Accuracy 0back	

Note: RT = Reaction Time; SSRT = Stop Signal Reaction Time, calculated using the integration method. Positive values indicate increased cognitive load or interference, while negative values indicate cognitive advantage. All indices were z-standardized within each dataset to ensure valid cross-task comparisons.

382

383 **2.5.2 跨任务认知一致性检验**

384 认知心理学理论认为，测量相同认知构念的不同任务应表现出内在一致性
385 (Binz et al., 2025)。本研究通过系统的跨范式相关分析检验这一理论预期在大语
386 言模型中是否成立，并与人类数据进行比较验证。分析采用两个层次的验证策略。
387 首先进行域内一致性分析，检验同一执行功能域内不同任务的相关性：在抑制控
388 制域，比较 Stroop 干扰效应与 Go/No-go 抑制效应的相关；在工作记忆域，比较
389 n-back 任务表现（正确率）与数字活动记忆任务正确率的相关；在认知灵活性域，
390 检验任务转换代价与其他灵活性指标的关联。其次进行域间关联分析，通过构建
391 完整相关矩阵，检验不同认知域之间的相关是否显著低于域内相关，以验证执行
392 功能的层级结构。采用 Fisher's z 变换对相关系数进行比较，并使用置换检验
393 (permutation test, $n = 5,000$) 评估差异的显著性。通过对比大语言模型与人类在

相同构念测量上的一致性模式, 评估模型执行功能模拟的内在逻辑性和结构有效性。如果模型能够复现人类的域内高相关和域间低相关模式, 则提示其捕获了执行功能的核心组织原则。

2.5.3 大语言模型对数概率参数与脑区激活关联分析

为探究大语言模型的内部计算机制与人类脑活动的对应关系, 本研究将模型的对数概率参数变化与执行功能相关脑区的激活强度进行系统比较。针对每个执行功能任务, 独立进行脑-模型对应分析。首先, 进行 ROI 定义与激活提取。对每个被试, 基于其余所有被试的 fMRI 数据构建组水平 GLM, 生成任务效应激活图 (如 Stroop 任务"不一致">"一致"对比)。根据激活峰值 (cluster-level FWE correction, $p < 0.05$) 确定感兴趣区, 以峰值坐标为中心构建 6mm 半径球形 ROI, 涵盖背外侧前额叶皮层、前扣带回皮层、下额叶回等执行控制核心脑区。为确保数据独立性, 采用留一法 (leave-one-out) 策略, 即定义 ROI 时排除目标被试数据, 随后从该被试的独立数据中提取相应 ROI 的平均激活强度 (β 值)。其次, 计算模型参数。相应地, 计算大语言模型在相同任务对比条件下的对数概率参数差值, 包括困惑度、对数概率方差、平均对数概率和最小对数概率的条件间差异。这些参数反映了模型在不同认知负荷条件下的内部计算状态变化, 可作为模型"认知努力"的代理指标。随后, 进行脑-模型映射分析。使用大语言模型的 4 个对数概率参数作为预测变量, 为每个 ROI 建立独立的岭回归模型 (Ridge Regression), 以预测人脑 ROI 的激活模式。岭回归的正则化参数 λ 通过网格搜索 5 折交叉验证评估模型性能, 计算预测准确性指标 (R^2 和均方误差)。最后, 基于 SciPy 进行表征相似性分析 (Representational Similarity Analysis, RSA), 构建人脑 ROI 激活模式与模型参数模式的相似性矩阵, 并通过 Spearman 秩相关系数量化两者的对应关系。为评估相似性的统计显著性, 采用置换检验 ($n = 3,000$) 生成零分布。为控制多重比较问题, 对所有统计检验采用 FDR 校正 ($\alpha = 0.05$)。本分析的最终目标是识别大语言模型内部计算过程与人脑神经活动模式的潜在映射关系, 从而为理解 AI 认知机制提供神经科学视角的证据 (Du et al., 2025)。

3 结果

3.1 大语言模型选择性复现人类执行功能的经典效应

3.1.1 执行功能核心成分的行为表现

(1) 干扰抑制: Stroop 色词任务

在 Stroop 色词任务中, LLMs 有效复现了人类被试的干扰效应, 表现出相似的认知加工模式 (见 图 3)。对于 LLMs, 单因素方差分析结果表明不同条件间存在显著差异 ($F = 35.40, p < 0.001$)。事后比较分析显示, 不一致条件下的反应时 (504.98 ± 30.93 ms) 显著长于一致条件 (445.06 ± 30.42 ms; $t = 7.57, p < 0.001, d = 1.95$) 和中性条件 (456.49 ± 26.29 ms; $t = 6.57, p < 0.001, d = 1.69$)。一致条件与中性条件之间的差异相对较小且未达到统计显著水平 ($t = 1.56, p = 0.13, d = 0.40$)。人类被试组呈现出相似的反应模式。条件间差异达到统计显著水平 ($F = 3.57, p = 0.031$), 其中不一致条件 (618.47 ± 119.82 ms) 的反应时长于一致条件 (564.67 ± 92.78 ms; $t = 2.38, p = 0.019, d = 0.50$) 和中性条件 (573.37 ± 92.52 ms; $t = 2.00, p = 0.049, d = 0.42$)。贝叶斯差异检验进一步验证了两组间的相似性。LLMs 的平均干扰效应为 59.92 ms (SD = 12.93), 所有被试均表现出正向干扰效应。人类被试的平均干扰效应为 52.31 ms (SD = 79.58), 其中 84.4% 的被试表现出正向效应。两组在干扰效应方向上的一致概率达到 90.7% (95% HDI: [0.85, 0.96], $BF_{10} = 9.73$), 提供了中等强度的支持证据。

进一步的分析发现, LLMs 的对数概率参数在不同条件下呈现系统性变化。困惑度在不一致条件下显著高于一致条件 ($p = 0.003, d = 0.80$), 单因素方差分析确认了条件间的总体差异 ($F = 3.90, p = 0.025, \eta^2 = 0.082$)。对数概率方差显示出更为明显的条件效应 ($F = 7.42, p = 0.001, \eta^2 = 0.147$), 不一致条件显著高于一致条件 ($p < 0.001, d = 0.93$) 和中性条件 ($p = 0.031, d = 0.58$)。相关分析揭示了对数概率参数与行为表现之间的系统性关联。LLMs 反应时与困惑度 ($r = 0.329, p_{fdr} = 0.002$) 和对数概率方差 ($r = 0.398, p_{fdr} < 0.001$) 呈正相关, 与平均对数概率 ($r = -0.331, p_{fdr} = 0.002$) 和最小对数概率 ($r = -0.390, p_{fdr} < 0.001$) 呈负相关。

这些关联在一致条件下表现得最为显著 (困惑度: $r = 0.432, p_{fdr} = 0.068$; 最小对数概率: $r = -0.484, p_{fdr} = 0.068$), 而在不一致和中性条件下均未达到显著水平 (所有 $p_{fdr} > 0.50$), 表明内部计算状态与行为表现之间的关系可能受到任务难度的调节作用。




图 3 Stroop 色词干扰任务中大语言模型与人类被试的行为表现比较

(2) 反应抑制: Go/No-Go 任务

在 Go/No-Go 任务中, LLMs 未能复现人类被试的反应抑制特征 (见 图 4)。LLMs 表现出完全的抑制成功, 即零抑制失败率 (Go 试次: $100.0\% \pm 0.0\%$; No-Go

试次: $100.0\% \pm 0.0\%$)。不同的是, 人类被试表现出典型的 Go/No-Go 效应模式, Go 试次的准确率 ($98.1\% \pm 2.7\%$) 显著高于 No-Go 试次 ($85.1\% \pm 15.6\%$; $t = 5.50$, $p < 0.001$, $d = 1.16$)。单因素方差分析证实了人类被试在不同试次类型间存在显著差异 ($F = 30.23$, $p < 0.001$)。通过计算抑制控制效应 (Go 准确率减去 No-Go 准确率) 进一步揭示了两组间的根本差异。LLMs 的平均抑制控制效应为 0, 表明模型在该任务中达到了天花板效应。然而, 人类被试的平均抑制控制效应为 13.0% ($SD = 15.7\%$), 其中 97.8% 的被试表现出正向的抑制控制效应, 即 No-Go 试次的错误率高于 Go 试次。贝叶斯层级模型分析显示, 两组在抑制控制模式上的方向一致性概率仅为 25.5% (95% HDI: $[0.20, 0.31]$, $BF_{10} = 0.34$), 表明存在反对方向一致性的证据。

有趣的是, 尽管 LLMs 在任务执行的准确性上达到了天花板效应, 但其内部状态参数仍然表现出条件间的系统性差异。困惑度分析显示, No-Go 试次显著高于 Go 试次 ($t = 5.91$, $p < 0.001$, $d = 1.55$), 单因素方差分析证实了显著的条件效应 ($F = 34.92$, $p < 0.001$, $\eta^2 = 0.384$)。对数概率方差同样表现出显著的条件差异 ($F = 28.49$, $p < 0.001$, $\eta^2 = 0.337$), No-Go 试次显著高于 Go 试次 ($t = 5.34$, $p < 0.001$, $d = 1.40$)。平均对数概率在 No-Go 试次比 Go 试次更负 ($t = 5.92$, $p < 0.001$, $d = 1.56$), 最小对数概率也呈现相似的模式 ($t = 5.83$, $p < 0.001$, $d = 1.53$)。这些内部状态的变化表明, 尽管 LLMs 在行为层面未表现出抑制失败, 但其在处理 No-Go 刺激时表现出更高的统计处理复杂度。




图 4 Go/No-Go 任务中大语言模型与人类被试的反应抑制表现比较

(3) 工作记忆容量：数字正背与倒背任务

数字广度任务中，LLMs 有效复现了人类被试典型的正背-倒背广度差异，但效应强度存在显著差别（见 图 5）。LLMs 正向广度的最大值 (14.7 ± 1.64) 显著高于倒背广度 (11.2 ± 2.16 ; $t = 7.07, p < 0.001, d = 1.83$)，表现出 3.5 个单位的平均差异。人类被试同样表现出正背优势效应，正向广度 (9.36 ± 1.67) 高于倒背广度 (8.18 ± 1.76 ; $t = 3.26, p = 0.002, d = 0.69$)，但平均差异仅为 1.18 个单位。单因素方差分析证实了人类被试在任务类型间的显著差异 ($F = 10.61, p = 0.002$)。贝叶斯差异检验发现，两组在工作记忆效应方向上的一致概率为 26.0% (95% HDI: [0.21, 0.31] , $BF_{1-0} = 1.05$)，未能提供方向一致性的有力证据。值得注意的是，LLMs 的工作记忆效应标准差 (2.91) 显著高于人类被试 (1.44)，表明模型间存

在较大的个体差异。

LLMs 的内部状态参数与任务难度表现出系统性关联。在试次水平的相关分析中, 序列长度与困惑度在正向任务 ($r = 0.348, p_{fdr} < 0.001$) 和倒背任务 ($r = 0.644, p_{fdr} < 0.001$) 中均呈显著正相关, 且倒背任务中的相关性明显更强。对数概率方差同样显示出任务特异性的模式, 在倒背任务中 ($r = 0.414, p_{fdr} < 0.001$) 的相关性高于正向任务 ($r = 0.218, p_{fdr} < 0.001$)。平均对数概率和最小对数概率与序列长度呈负相关, 在倒背任务中的相关性 (平均: $r = -0.621$; 最小: $r = -0.657$, 均 $p_{FDR} < 0.001$) 强于正向任务 (平均: $r = -0.351$; 最小: $r = -0.340$, 均 $p_{FDR} < 0.001$)。在被试水平的分析中, 倒背任务的困惑度显著高于正向任务 ($t = 10.99, p < 0.001, d = 2.84$), 对数概率方差在倒背任务中也显著高于正向任务 ($t = 4.87, p < 0.001, d = 1.31$)。




图 5 数字广度任务中大语言模型与人类被试的工作记忆广度表现比较

(4) 工作记忆刷新：数字活动记忆任务

在数字活动记忆任务中，LLMs 未能复现人类被试在时间压力条件下的工作记忆刷新特征（见 图 6）。对于 LLMs，两种刺激呈现时间条件下的准确率几乎相同（1750ms: $95.14\% \pm 4.11\%$; 750ms: $95.28\% \pm 6.81\%$ ），条件间差异不显著（ $t = 0.10, p = 0.924, d = 0.025$ ）。相比之下，人类被试表现出典型的时间压力效应，1750ms 条件下的准确率（ $92.04\% \pm 6.75\%$ ）显著高于 750ms 条件（ $85.46\% \pm 10.57\%$; $t = 3.52, p < 0.001, d = 0.74$ ）。单因素方差分析证实了人类被试在不同时间条件间存在显著差异（ $F = 12.36, p < 0.001$ ）。工作记忆刷新效应（1750ms 准确率减去 750ms 准确率）的分析进一步揭示了两组间的差异。LLMs 的平均刷新效应接近零（ -0.14% ），表明时间压力对其表现几乎没有影响。人类被试的平均刷新效应为 6.58% （ $SD = 8.84\%$ ），其中 73.3% 的被试表现出正向刷新效应，即在较长呈现时间下表现更好。贝叶斯层级模型分析显示，两组在刷新效应方向上的一致概率为 50.1%（95% HDI: [0.45, 0.55]， $BF_{10} = 1.00$ ），表明缺乏方向一致性的证据。尽管 LLMs 在行为层面未表现出时间压力效应，其内部状态参数显示出细微但系统性的变化。困惑度在两种条件下极其接近，差异未达显著水平（ $t = 0.80, p = 0.428, d = 0.21$ ）。对数概率方差在 750ms 条件下略高于 1750ms 条件，但差异同样不显著（ $t = 1.23, p = 0.228, d = 0.32$ ）。平均对数概率和最小对数概率在两种条件下同样表现出极小的差异（均 $p > 0.40$ ），表明模型的内部处理状态在不同时间压力下保持相对稳定。




图 6 大语言模型与人类被试在不同间隔时间条件下数字活动记忆任务中的表现比较

(5) 认知灵活性：数字转换任务

在任务转换范式中，LLMs 未能复现人类在任务转换中的典型转换代价模式（见 图 7）。对于 LLMs，混合条件下转换试次的反应时 (450.27 ± 55.34 ms) 与重复试次 (449.39 ± 54.13 ms) 几乎相同，转换代价仅为 0.88 ms ($t = 0.06, p = 0.951, d = 0.016$)，未达显著水平。相比之下，人类被试表现出典型的转换代价，转换试次的反应时 (1328.33 ± 341.46 ms) 显著长于重复试次 (1134.28 ± 282.69 ms)，产生 194.05 ms 的平均转换代价 ($t = 2.94, p = 0.004, d = 0.62$)。混合代价的分析显示了更为一致的模式。LLMs 在混合条件 (449.83 ± 53.48 ms) 与单任务条件 (409.00 ± 54.99 ms) 间表现出 40.83 ms 的混合代价 ($t = 2.88, p = 0.005, d = 0.75$)。人类被试的混合代价为 143.21 ms，混合重复试次 (1134.28 ms) 显著慢于单任务试次 (991.07 ± 241.00 ms; $t = 2.59, p = 0.011, d = 0.54$)。贝叶斯差异检验显示，

两组在转换代价方向上的一致概率为 67.9% (95% HDI: [0.62, 0.74] , $BF_{10} = 2.11$)，提供了有限的方向一致性证据。值得注意的是，60.0%的 LLMs 表现出正向转换代价，而 86.7%的人类被试表现出正向转换代价。

LLMs 的内部状态参数在不同条件间未表现出显著差异。困惑度在转换试次、重复试次和单任务试次间无显著差异 (所有比较的 $p > 0.24$)。对数概率方差、平均对数概率和最小对数概率在三种条件间同样保持相对稳定 (所有 $p > 0.16$)，表明模型的统计处理参数在不同任务条件下保持稳定。转换代价与内部状态参数的相关分析显示，反应时的转换代价与困惑度 ($r = 0.003$)、对数概率方差 ($r = -0.118$)、平均对数概率 ($r = -0.006$) 和最小对数概率 ($r = 0.004$) 的相关性均接近零且不显著 (所有 $p > 0.50$)。




图 7 数字字母转换任务中大语言模型与人类被试的任务转换代价比较

3.1.2 基于机器学习的执行功能多维度识别

当前为测试结果，样本量较少，后续完成。

3.2 大语言模型执行功能的跨任务泛化验证

数据未拿到，后续完成。

3.3 大语言模型对数概率参数与人脑神经活动的映射关系

3.3.1 独立样本的执行功能任务验证

为验证 LLMs 在不同执行功能范式中的表现一致性，我们对数据集 2 中的三项任务进行了系统分析。在 N-Back 任务中，LLMs 表现出典型的工作记忆负荷效应(见 图 8)。随着 N-Back 水平的提高，准确率呈现系统性下降 (0-back: 100.0% $\pm$ 0.0%; 1-back: 93.2% $\pm$ 3.4%; 2-back: 82.1% $\pm$ 10.9%)，单因素方差分析显示主效应显著 ($F = 50.48, p < 0.001$)。事后比较表明，各条件间均存在显著差异：0-back 与 1-back ($d = 2.85$)、0-back 与 2-back ($d = 2.34$) 以及 1-back 与 2-back ($d = 1.38$)。反应时随工作记忆负荷增加而递增 (0-back: 462.85 $\pm$ 7.96 ms; 1-back: 464.90 $\pm$ 8.77 ms; 2-back: 466.65 $\pm$ 7.08 ms)，尽管未达显著水平 ($F = 1.51, p = 0.228$)。N-Back 效应 (2-back 减去 0-back) 分析显示，准确率下降 17.91% ($t = -8.34, p < 0.001$)，反应时增加 3.05 ms ($t = 3.84, p < 0.001$)。这种准确率的显著下降配合反应时的小幅增加，表明 LLMs 在高工作记忆负荷下主要表现为准确性的损失。内部状态参数随工作记忆负荷表现出系统性变化。困惑度从 0-back (1.028 $\pm$ 0.005) 降低到 2-back (1.017 $\pm$ 0.005)，N-Back 效应为 -0.011 ($t = -7.30, p < 0.001$)。对数概率方差同样显示负荷依赖性降低，N-Back 效应为 -0.005 ($t = -7.61, p < 0.001$)。平均对数概率和最小对数概率随负荷增加而变得更正 (均 $p < 0.001$)。进一步的相关分析发现，模型准确率与内部状态参数呈现强相关：与困惑度 ($r = 0.529, p_{fdr} < 0.001$) 和对数概率方差 ($r = 0.534, p_{fdr} < 0.001$) 呈正相关，与平均对数概率 ($r = -0.533, p_{fdr} < 0.001$) 和最小对数概率 ($r = -0.587, p_{fdr} < 0.001$) 呈负相关。而反应时与内部状态参数的整体相关较弱 (困惑度: $r = 0.124$; 对数概率方差: $r = 0.147$; 平均对数概率: $r = -0.120$; 最小对数概率: $r = -0.061$, 所有 $p_{fdr} > 0.05$)。

在停止信号任务中，LLMs 表现出有效的反应抑制能力。分析被试在 Go 成功试次和 Stop 成功试次中的表现，结果显示两种条件下的内部状态参数存在显著差异（见 图 8）。Stop 成功试次相比 Go 成功试次，困惑度显著增加 ($t = 4.48, p < 0.001, d = 0.88$)，对数概率方差同样更高 ($t = 3.49, p = 0.002, d = 0.69$)。平均对数概率显著降低 ($t = -4.44, p < 0.001, d = -0.87$)，最小对数概率表现出更负的值 ($t = -5.25, p < 0.001, d = -1.03$)。所有四个内部状态参数在 Stop 成功与 Go 成功条件间的差异均达到中等到大的效应量 ($d = 0.69-1.03$)，其中最小对数概率的差异最为显著。

与前述任务不同的是，在字母数字转换任务中，LLMs 未表现出人类的转换代价模式（见 图 8）。反应时上几乎不存在转换代价（转换： 394.16 ± 28.75 ms；重复： 394.79 ± 29.26 ms；差值： -0.63 ± 2.60 ms， $t = -1.24, p = 0.228, d = 0.022$ ）。然而，内部状态参数揭示了显著的转换代价效应。困惑度在转换试次 (1.018 ± 0.007) 显著高于重复试次 (1.012 ± 0.005)，产生 0.006 的转换代价 ($t = 5.46, p < 0.001, d = 1.07$)。对数概率方差、平均对数概率和最小对数概率均表现出显著的转换代价（所有 $p < 0.001, d = 1.03-1.11$ ）。这表明尽管反应时上的转换代价接近零，所有内部状态参数均表现出大效应量的转换代价。




图 8 数据集 2 中执行功能任务的行为表现

3.3.2 模型内部状态对脑区激活的预测分析

为探究大语言模型内部状态参数与人类脑区激活之间的对应关系，本研究采用岭回归分析方法，通过基于相似性的匹配策略将 AI 参与者的认知参数差异与人类参与者的 fMRI 数据进行关联（见 图 9）。在停止信号任务中，我们分析了 Stop 成功与 Go 成功条件间的差异对 18 个脑区激活的预测效果。结果显示，右侧颞上回的预测性能最佳（交叉验证 $R^2 = 0.593$, $r = 0.829$, $p < 0.001$ ），其次为左侧颞中回（CV $R^2 = 0.458$ ）和后扣带回（CV $R^2 = 0.234$ ）。特征重要性分析表明，最小对数概率差异贡献最大（重要性得分：0.352），提示模型在反应抑制过程中的确定性变化是预测脑激活的关键指标（见 图 10）。

在 N-back 任务中，对 2-back 与 0-back 条件差异预测 6 个工作记忆相关脑区

605 激活的分析显示 (见 图 10), 左侧顶下小叶的预测效果最优 ($CV R^2 = 0.605, r =$
606 $0.894, p < 0.001$), 左侧额下回 ($CV R^2 = 0.549$) 和左侧颞中回 ($CV R^2 = 0.441$)
607 的预测性能也较为理想。困惑度在特征重要性分析中占据首位 (重要性得分:
608 0.282)。值得注意的是, 左侧语言网络相关脑区均表现出较强的预测性能 ($R^2 >$
609 0.44), 而右侧颞中回的预测效果较差 ($R^2 = -0.177$)。这种左侧优势可能反映了
610 语音工作记忆在任务执行中的主导作用。此外, 左侧额下回激活与困惑度呈负相
611 关 ($\beta = -0.518$), 表明当模型处理信息的确定性较高时, 执行控制相关区域的激
612 活程度更强。在字母数字转换任务中, 对转换试次与重复试次差异预测 19 个认
613 知控制相关脑区激活的分析显示 (见 图 10), 中央辅助运动区的预测性能最佳
614 ($CV R^2 = 0.659, r = 0.853, p < 0.001$), 右侧前扣带回 ($CV R^2 = 0.560$) 和右侧辅
615 助运动区 ($CV R^2 = 0.450$) 紧随其后。最小对数概率差异在该任务中同样显示出
616 最高的特征重要性 (重要性得分: 0.333)。辅助运动区-前扣带回执行控制系统的
617 激活与模型内部不确定性的增加呈现直接关联。右侧岛叶表现出的中等预测性能
618 ($R^2 = 0.254$) 支持了其在任务切换过程中协调不同神经网络转换的功能作用。






图 9 执行功能任务的脑激活模式与感兴趣区域 (ROI) 提取


Stop Success vs Go Success



Switch vs Non-switch



2-back vs 0-back



620 图 10 大语言模型内部状态与人脑活动的岭回归与表征相似性分析

621

622 3.3.3 认知表征的相似性分析

623 为评估大语言模型内部状态与人类脑区激活之间的表征结构相似性, 本研究
 624 对三项执行功能任务进行了表征相似性分析 (RSA)。分析基于大语言模型参与
 625 者的认知参数和人类参与者相应脑区的激活数据, 采用基于相似性的配对方法对
 626 独立样本进行匹配。通过计算认知参数和感兴趣区激活的表征相异矩阵 (RDM),
 627 使用欧氏距离度量样本间的相异性, 并通过 Spearman 相关系数比较两个 RDM
 628 的上三角元素。在停止信号任务中, 我们分析了 4 个认知参数差异 (Stop 成功减
 629 去 Go 成功) 与 18 个脑区激活之间的表征相似性。结果显示, RSA 相关系数为

0.078 ($p = 0.172$), 未达到统计显著水平 (见 图 10)。为验证结果的稳健性, 我们采用多种距离度量进行敏感性分析。其中, 基于欧氏距离的 Pearson 相关显示出边缘显著趋势 ($r = 0.100, p = 0.072$), 但仍未达到传统的显著性阈值。基于相关距离和余弦距离的分析均未发现显著关系 (所有 $p > 0.34$)。在字母数字转换任务中, 对 4 个认知参数与 19 个认知控制相关脑区激活的表征相似性分析显示, RSA 相关系数仅为 0.035 ($p = 0.534$), 未达到显著水平。所有敏感性分析方法得到的相关系数均接近零 ($|r| < 0.03$, 所有 $p > 0.63$), 进一步证实了该任务中模型内部状态与脑激活表征结构之间缺乏显著关联。

然而, 在 N-back 任务中, 分析结果呈现出不同的模式。对 4 个认知参数 (包括 2-back 与 0-back 条件差异) 与 6 个工作记忆相关脑区激活的表征相似性分析显示出显著正相关 ($r = 0.259, p < 0.001$) (见 图 10), 表明认知参数与感兴趣区激活之间存在中等程度的表征相似性。敏感性分析进一步验证了结果的稳健性: 基于欧氏距离的 Pearson 相关表现出更强的关联 ($r = 0.285, p < 0.001$), 余弦距离分析也发现了显著相关 (Spearman: $r = 0.142, p = 0.010$)。

3.4 敏感性与补充性分析

(1) 其他大模型, 如 Claude 系列模型 (Claude-3-Opus、Claude-3-Sonnet)

(2) 不同采样方法和参数设置下的模型表现

参考文献

- Abraham, A., Pedregosa, F., Eickenberg, M., Gervais, P., Mueller, A., Kossaifi, J., Gramfort, A., Thirion, B., & Varoquaux, G. (2014). Machine learning for neuroimaging with scikit-learn. *Frontiers in Neuroinformatics*, 8, 14. <https://doi.org/10.3389/fninf.2014.00014>
- Bauer, C., Duc Dang, L. T., van den Beucken, T., Schuchhardt, J., & Herwig, R. (2025). Systematic analysis of hepatotoxicity: Combining literature mining and AI language models. *Frontiers in Artificial Intelligence*, 8. <https://doi.org/10.3389/frai.2025.1561292>
- Benjamini, Y., Drai, D., Elmer, G., Kafkafi, N., & Golani, I. (2001). Controlling the false discovery rate in behavior genetics research. *Behavioural Brain Research*, 125(1), 279–284. [https://doi.org/10.1016/S0166-4328\(01\)00297-2](https://doi.org/10.1016/S0166-4328(01)00297-2)
- Binz, M., Akata, E., Bethge, M., Brändle, F., Callaway, F., Coda-Forno, J., Dayan, P., Demircan, C., Eckstein, M. K., Éltető, N., Griffiths, T. L., Haridi, S., Jagadish, A. K., Ji-An, L., Kipnis, A., Kumar, S., Ludwig, T., Mathony, M., Mattar, M., ... Schulz, E. (2025). A foundation model to predict and capture human cognition. *Nature*, 1–8. <https://doi.org/10.1038/s41586-025-09215-4>
- Coda-Forno, J., Binz, M., Wang, J. X., & Schulz, E. (2024). *CogBench: A large language model walks into a psychology lab* (20 citation(s); No. arXiv:2402.18225). arXiv. <https://doi.org/10.48550/arXiv.2402.18225>
- Du, C., Fu, K., Wen, B., Sun, Y., Peng, J., Wei, W., Gao, Y., Wang, S., Zhang, C., Li, J., Qiu, S., Chang, L., & He, H. (2025). Human-like object concept representations emerge naturally in multimodal large language models. *Nature Machine Intelligence*, 7(6), 860–875. <https://doi.org/10.1038/s42256-025-01049-z>
- Feng, J., Zhang, L., Chen, C., Sheng, J., Ye, Z., Feng, K., Liu, J., Cai, Y., Zhu, B., & Yu, Z. (2022). A cognitive neurogenetic approach to uncovering the structure of executive functions. *Nature Communications*, 13(1), 4588. <https://doi.org/10.1038/s41467-022-32383-0>
- Gomez, P., Ratcliff, R., & Perea, M. (2007). A model of the go/no-go task. *Journal of Experimental Psychology: General*, 136(3), 389. <https://doi.org/10.1037/0096-3445.136.3.389>
- Gong, D., Wan, X., & Wang, D. (2024). Working Memory Capacity of ChatGPT: An Empirical Study. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(9), 10048–10056. <https://doi.org/10.1609/aaai.v38i9.28868>
- He, L., Zhuang, K., Chen, Q., Wei, D., Chen, X., Fan, J., & Qiu, J. (2021). Unity and diversity of neural representation in executive functions. *Journal of Experimental Psychology: General*, 150(11), 2193–2207. <https://doi.org/10.1037/xge0001047>
- Hu, X., & Lewis, R. L. (2024). *Do Language Models Understand the Cognitive Tasks Given to Them? Investigations with the N-Back Paradigm* (No. arXiv:2412.18120). arXiv. <https://doi.org/10.48550/arXiv.2412.18120>
- Kosinski, M. (2024). Evaluating large language models in theory of mind tasks. *Proceedings of the National Academy of Sciences*, 121(45), e2405460121. <https://doi.org/10.1073/pnas.2405460121>
- Kray, J., Li, K. Z., & Lindenberger, U. (2002). Age-related changes in task-switching components:

-
- 688 The role of task uncertainty. *Brain and Cognition*, 49(3), 363–381.
689 <https://doi.org/10.1006/brcg.2001.1505>
- 690 Miller, E. J., Steward, B. A., Witkower, Z., Sutherland, C. A., Krumhuber, E. G., & Dawel, A.
691 (2023). AI hyperrealism: Why AI faces are perceived as more real than human ones.
692 *Psychological Science*, 34(12), 1390–1403. <https://doi.org/10.1177/09567976231207095>
- 693 Stroop, J. R. (1935). Studies of interference in serial verbal reactions. *Journal of Experimental*
694 *Psychology*, 18(6), 643–662. <https://doi.org/10.1037/h0054651>
- 695 Suri, G., Slater, L. R., Ziaee, A., & Nguyen, M. (2024). Do large language models show decision
696 heuristics similar to humans? A case study using GPT-3.5. *Journal of Experimental*
697 *Psychology: General*, 153(4), 1066–1075. <https://doi.org/10.1037/xge0001547>
- 698 Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., &
699 Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing*
700 *Systems*, 30.
- 701 Veenman, M., Stefan, A. M., & Haaf, J. M. (2024). Bayesian hierarchical modeling: An
702 introduction and reassessment. *Behavior Research Methods*, 56(5), 4600–4631.
703 <https://doi.org/10.3758/s13428-023-02204-3>
- 704 Wang, C., Wang, J., Zeng, X., Yu, N. X., & Chen, T. (2025). Are Memory Updating Tasks Valid
705 Working Memory Measures? A Meta-Analysis. *Lifespan Development and Mental Health*,
706 1(1), Article 1. <https://doi.org/10.70322/ldmh.2025.10003>
- 707 Yan, C.-G., Wang, X.-D., Zuo, X.-N., & Zang, Y.-F. (2016). DPABI: data processing & analysis
708 for (resting-state) brain imaging. *Neuroinformatics*, 14(3), 339–351.
709 <https://doi.org/10.1007/s12021-016-9299-4>
- 710 Yangüez, M., Bediou, B., Chanal, J., & Bavelier, D. (2024). In search of better practice in
711 executive functions assessment: Methodological issues and potential solutions. *Psychological*
712 *Review*, 131(2), 402–430. <https://doi.org/10.1037/rev0000434>

后 续 研 究

基于执行功能多任务范式的大语言模型微调与神经对齐研究

已有数据资源

行为数据: 数据集 1 西北师范大学: 包含 5 项执行功能任务的行为按键数据 ($N = 8,000$), 一套完整执行功能测试包含 818 个试次/一个被试。

神经影像数据: 数据集 2 北京师范大学: 包含 9 项执行功能行为按键任务及静息态 MRI 数据 ($N = 870$); 数据集 3 西南大学: 包含 3 项执行功能行为按键任务及相应的任务态 MRI 数据 ($N = 39$); 数据集 4 西北师范大学: 包含 N -back、Sternberg 和推理行为按键任务及相应的任务态 MRI 数据 ($N = 62$)。

提示设计与指令微调 (Instruction Fine-Tuning) 策略

为将 E-prime 平台记录的人类行为数据转换为 LLM 可处理的格式, 我们设计了基于 ChatML 格式 (OpenAI, 2023) 的多轮对话结构 (<https://platform.openai.com/docs/guides/fine-tuning - multi-turn-chat-examples>)。每个实验试次被构建为对话中的一轮交互, 完整实验的所有试次构成一个连贯的对话序列 (见 下图)。这种设计基于两个关键考虑: (1) 保留试次间的顺序依赖关系; (2) 利用 LLM 的上下文理解能力捕获任务序列模式 (Binz et al., 2024)。




图 人类认知行为数据转换为大语言模型微调训练的数据流程图

注：该流程图展示将 E-prime 平台采集的人类执行功能行为数据转换为适用于大语言模型微调的训练数据的完整过程。上层显示了单个被试在执行功能任务中的试次序列，包括指导语、刺激呈现和反应记录；中层首先将原始行为数据转换为自然语言描述，然后将自然语言文本转换为标准化的输入序列（Input ids）、注意力掩码（Attention mask）和标签序列（Labels）；下层描述了微调过程中的神经网络架构，通过拆分、合并操作在训练层和冻结层之间进行参数更新，使用负对数似然损失函数（ $\text{loss} = -\log x$ ）优化模型以接近人类被试的数据模式。