

What executive functions can and cannot be replicated in large language models: A case study using GPT-4o

摘要

引言：大语言模型在需要执行功能支持的复杂认知任务中表现出类人特征，但其能否在经典执行功能实验范式中复现人类的认知加工模式仍是未知。本研究以 GPT-4o 为例，系统评估了大语言模型在抑制控制、工作记忆和认知灵活性三个核心维度上的表现，并探究了对数概率参数作为量化大语言模型认知加工过程指标的可行性。

方法：本研究使用两个独立数据集 ($N_1 = 1,970$; $N_2 = 39$)，通过 GPT-4o 模拟完成逐试次按键反应任务，同步记录模型对数概率参数。采用贝叶斯方差分析比较人类与模型的行为表现差异，并进一步探究对数概率参数与人脑神经活动的对应关系。

结果：研究发现，GPT-4o 选择性地复现了人类执行功能的部分子成分效应。在干扰抑制 (*Stroop* 任务)、工作记忆容量 (数字广度任务) 和工作记忆刷新 (*N-back* 任务) 中，模型表现出与人类相似的认知效应模式；而在反应抑制 (*Go/No-Go* 任务)、时间压力下的工作记忆刷新 (活动记忆任务, 1750ms vs 750ms 呈现时间) 和认知灵活性 (任务转换范式) 中，模型未能复现人类的典型表现模式。对数概率参数与行为指标呈现任务特异性关联，部分参数变化与执行功能相关脑区激活强度存在显著相关。

结论：GPT-4o 能够选择性地模拟人类执行功能的特定子成分，特别是基于符号表征和静态信息维持的认知过程，但在涉及动态控制和时间敏感性的任务中表现出明显局限。这种选择性复现模式为理解执行功能的计算本质提供了新视角。对

27 数概率参数在特定任务情境下可作为模型认知加工的内部指标, 为评估大语言模
28 型的认知机制提供了新的分析维度。未来研究需要在更多大语言模型架构、不同
29 人群样本和执行功能理论框架下进一步验证这些发现。

30 **关键词：**执行功能；大语言模型；GPT；对数概率参数；人工智能

31

32

1 引言

大语言模型 (Large Language Models, LLMs) 在需要复杂认知加工的推理和问题解决任务中表现出接近人类的水平, 包括多步推理 (Hagendorff et al., 2023)、策略规划 (Valmeekam et al., 2022) 和抽象概念操作 (Webb et al., 2023)。这一现象引发了一个根本性问题: 基于统计学习的计算系统能否在测量认知功能的经典实验范式中展现出类人特征? 这个问题不仅关系到我们对认知加工计算基础的理解, 也为认知科学研究开辟了新的研究路径 (Chemero, 2023; Frank, 2023; Ke et al., 2025; Meng, 2024)。通过系统比较模型与人类的行为模式, 我们可以探究哪些认知过程能够通过大规模统计语言学习获得, 哪些可能依赖于人类特有的生物结构或经验基础 (Suri et al., 2024)。

作为人类认知架构的核心控制系统, 执行功能 (Executive Functions, EFs) 负责协调目标导向行为的实施, 与推理、决策等高阶认知能力密切相关 (Diamond, 2013; Friedman & Robbins, 2022)。近期研究已开始探索 LLMs 在执行功能任务中的表现。在工作记忆领域, 研究发现 LLMs 表现出与人类相似的容量限制 (Gong et al., 2024; Zhang et al., 2024), 但系统评估显示不同模型间存在显著的性能差异, 这表明该能力可能更多地取决于训练规模而非架构设计 (Hu & Lewis, 2024)。在认知灵活性和抑制控制方面, LLMs 面临更明显的挑战: 多项研究表明, 模型难以适应规则变化, 在冲突抑制任务中表现欠佳, 在需要前瞻性规划的任务中明显落后于人类 (Langis et al., 2025; Loconte et al., 2023; Valmeekam et al., 2022)。在更广泛的认知能力评估中, 研究发现 LLMs 虽能复现某些心理效应, 但同时表现出系统性偏差和不均衡的认知能力分布, 且模型规模的增加并不能保证在所有认知任务上的性能提升 (Coda-Forno et al., 2024; Cui et al., 2025; Langis et al., 2025)。这些研究表明, LLMs 在执行功能的某些维度上与人类存在相似性, 但这种选择性复制的边界和机制仍有待阐明。

执行功能是一个多维度的认知加工系统, 其核心成分既相互独立又彼此关联 (Miyake & Friedman, 2012)。自 Miyake 等人 (2000) 提出经典的三因子模型以来, 抑制控制 (inhibitory control)、工作记忆 (working memory) 和认知灵活性 (cognitive flexibility) 被广泛认为是执行功能的基本成分。这一理论框架得到了

大量神经影像学证据的支持：背外侧前额叶皮层主要负责工作记忆操作 (D'Esposito & Postle, 2015)，前扣带皮层监控认知冲突 (Botvinick et al., 2001)，额下回参与反应抑制过程 (Aron et al., 2014)。然而，现有关于 LLMs 执行功能的研究多聚焦于单一成分，缺乏基于完整理论框架的系统评估。目前尚不清楚 LLMs 是否全面复制了人类执行功能的不同维度，还是仅在特定成分上表现出相似能力。识别这种选择性复制的模式，有助于理解执行功能的哪些方面可以通过统计语言学习实现，哪些方面可能依赖于人类特有的认知架构 (Binz et al., 2025)。更为重要的是，当前关于大语言模型认知表现的研究主要停留在行为表现层面，缺乏对模型内部计算过程的深入探究。理解 LLMs 是否真正"复制"了认知过程，需要超越表面的行为相似性。认知神经科往往通过记录神经活动模式来推断认知过程；类似地，我们需要可量化的指标来探测模型的内部状态。OpenAI 的 GPT 系列模型开放的对数概率 (logprobs) 参数为此提供了新的技术途径。这些参数——包括困惑度、概率方差、平均对数概率和最小对数概率——反映了模型在生成响应时的统计不确定性和预测复杂度 (Bauer et al., 2025)。其动态变化模式可能为理解模型的"认知努力"提供重要线索，这对评估大语言模型能否真正模拟人类认知控制过程具有重要意义。然而，目前尚缺乏将行为表现与内部计算过程相结合的系统研究，这限制了我们对 LLMs 认知机制的深入理解。

综上所述，本研究采用经过广泛验证的三因子执行功能框架，以 GPT-4o 为例，系统评估当前 LLMs 在抑制控制、工作记忆和认知灵活性三个维度上能否复制人类执行功能的经典认知效应 (见 图 1)。此外，我们提取对数概率参数并将其与模型行为和人类神经活动 (i.g., fMRI 数据) 建立关联，从内部一致性和外部效度两个角度，探究其作为量化模型"认知内部加工"的候选代理指标的可能性。

2 方法

2.1 被试

本研究整合两个独立数据集进行分析 (见 表 1)。数据集 1 包括 1,970 名汉语母语者的执行功能行为测量数据。参与者均为成年人，平均年龄 19.78 岁 (标

准差 1.72 岁), 其中男性 915 名 (占 46.45%), 女性 1,055 名 (占 53.55%)。所有参与者完成了五项标准化认知任务, 包括 *Stroop* 色词任务、*Go/No-Go* 任务、数字转换任务、活动记忆任务以及数字正背和倒背任务, 用于系统评估执行功能的核心成分。参与者的纳入标准包括: 汉语为母语, 视力正常或矫正后正常, 无色盲或色弱。排除标准为: 存在神经系统疾病史、精神疾病史或药物滥用史, 以及正在服用可能影响认知功能药物的个体。所有参与者在实验前均签署了知情同意书, 实验程序符合相关伦理委员会的审批要求。本研究已获得西北师范大学伦理委员会批准。

数据集 2 采用 He 等人 (2021) 研究中的功能磁共振成像数据, 包含 39 名右利手本科生, 其中男性 13 名 (占 33.3%), 女性 26 名 (占 66.7%), 平均年龄 19.21 岁 (标准差 0.52 岁)。参与者在磁共振扫描环境下完成了三项执行功能任务, 包括 n-back 任务、停止信号任务和数字-字母类别转换任务。所有参与者均通过了 MRI 安全筛查, 确认无磁共振扫描禁忌症, 并在实验前签署了知情同意书。该数据集的 fMRI 扫描参数和具体任务程序遵循 He 等人 (2021) 的原始研究设计。

2.2 执行功能测量与研究程序

2.2.1 数据集 1 执行功能测量任务

基于 *Stroop* 色词任务测量干扰抑制能力: 采用计算机化版本的 *Stroop* 色词任务评估干扰抑制能力 (详见 补充材料)。参与者需忽略字义信息的干扰, 仅根据刺激颜色按键反应。任务包含一致、不一致和中性三种条件 (见 补充图 1), 以 *Stroop* 干扰效应 (不一致条件减去一致条件的反应时差值) 作为指标。实验采用事件相关设计, 包含练习模块 (18 试次) 和正式测试 (108 试次), 练习阶段要求达到 85% 正确率。任务持续约 15 分钟。

基于 *Go/No-Go* 任务测量反应抑制能力: 通过经典 *Go/No-Go* 范式评估反应抑制能力。参与者对目标字母快速按键反应, 对非目标字母抑制反应冲动。实验采用目标平衡设计 (4 模块×100 试次), 模块顺序在参与者间进行拉丁方平衡。主要指标为 No-Go 正确率和 Go 反应时, 练习阶段要求达到 85% 正确率。任务总

时长约 15 分钟。

基于数字转换任务测量认知灵活性:采用数字转换任务测量认知灵活性中的转换能力。任务由大小判断(红色数字)和奇偶判断(蓝色数字)两个子任务组成。实验包含单一任务组块(10 组块×8 试次)和混合任务组块(10 组块×17 试次),共 250 试次。转换代价通过比较混合组块中转换试次与重复试次的反应时差值来计算,练习正确率达到 75%后进入正式实验。任务持续约 15 分钟。

基于活动记忆任务测量工作记忆刷新能力:采用数字刷新任务(Running memory task)考察工作记忆刷新能力。参与者需不断更新并记住最后 3 个数字,任务分为简单条件(数字呈现 1750ms)和困难条件(750ms)。实验包含 4 个模块,每个模块 12 试次,序列长度为 5、7、9 和 11。简单和困难条件的平均正确率作为刷新能力指标。任务约需 20 分钟。

基于数字正背和倒背任务测量工作记忆广度:参照韦氏智力测验中的数字广度测验,采用数字正背和倒背任务评估工作记忆广度能力。数字正背任务要求参与者按原顺序回忆,倒背任务要求按相反顺序回忆。两项任务均采用适应性程序设计,难度从记忆 3 个数字开始,每个难度有 3 次机会。若回答正确次数≥2 次,记忆项目增加 1;否则任务结束。主要指标为最大记忆广度,两项任务的实施顺序在参与者间进行了平衡。

2.2.2 数据集 2 执行功能测量任务

基于n-Back 任务测量工作记忆:数字 n-back 任务包含 0-back、1-back 和 2-back 三种条件(见 补充图 1),以组块设计呈现。0-back 条件检测当前项目是否为"1";1-back 和 2-back 条件检测当前项目是否在序列中的前一次或前两次出现过。每种条件有 4 个组块(每组块 29 秒,包含 2 秒任务提示和 15 个刺激试次),组块间间隔 6 秒。三个任务以伪随机顺序呈现,连续重复不超过三次。

基于停止信号任务测量反应抑制:停止信号任务包括 32 个停止试次和 96 个执行试次。执行试次中,参与者根据绿色箭头方向按键;停止试次中,绿色箭头后呈现红色箭头作为停止信号,参与者需抑制已启动的反应。停止信号延迟(SSD)采用动态调整的阶梯程序,初始值为 250ms,成功抑制则增加 50ms,未成功抑制则减少 50ms。主要指标为停止信号反应时(SSRT)。试次间间隔为

1-4 秒 (平均 2.5 秒)。

基于数字-字母类别转换任务测量认知灵活性: 转换任务包括 48 个重复试次和 48 个转换试次。参与者根据字母颜色在奇偶判断 (红色字母) 和辅音/元音判断 (绿色字母) 之间转换。每个试次呈现 1000ms 注视点后, 呈现数字-字母对 2500ms。试次间间隔为 1-4 秒 (平均 2.5 秒)。当前试次的判断类型与前一试次相同时定义为重复试次, 否则为转换试次。主要指标为转换代价 (转换试次反应时减去重复试次反应时)。两种条件以伪随机顺序呈现, 重复不超过四次。

2.3 神经影像数据采集与处理

2.3.1 数据采集

神经影像数据采集的详细程序参照 He 等人 (2021) 的研究方案。所有磁共振成像数据均在西南大学脑成像中心采集, 使用配备 12 通道头部线圈的西门子 3T Trio 磁共振扫描仪 (Siemens Medical Systems, Erlangen, Germany)。功能磁共振成像采用回声平面成像 (EPI) 序列, 具体参数设置为: 重复时间 (TR) = 2000 ms, 回声时间 (TE) = 30 ms, 扫描层数 = 32, 层间距 = 1 mm, 翻转角 = 90°, 视野 (FOV) = 220×220 mm², 层厚 = 3 mm, 体素分辨率 = 3.4×3.4×3 mm³。结构成像采用磁化预备快速梯度回波 (MPRAGE) 序列获取高分辨率 T1 加权图像, 参数设置为: TR = 2530 ms, TE = 3.45 ms, 扫描层数 = 192, 翻转角 = 7°, FOV = 256×256 mm², 层厚 = 1 mm, 体素分辨率 = 1×1×1 mm³。扫描过程中使用泡沫垫固定被试头部以减少头动, 并通过耳塞降低扫描噪音对被试的影响。

2.3.2 fMRI 数据预处理

功能影像数据预处理采用 DPABI 工具包结合 SPM12 软件 (<http://www.fil.ion.ucl.ac.uk/spm>) 在 MATLAB 平台上实施(Yan et al., 2016)。预处理遵循标准化流程: 首先进行时间层校正以消除层间采集时间差异, 并实施头动校正以矫正扫描过程中的头部微小移动, 排除头动超过 3 mm 或旋转超过 3° 的数据; 其次将个体结构像配准到平均功能像以建立结构-功能对应关系; 第三, 采用 DARTEL 算法将结构像精确分割为灰质、白质和脑脊液三种组织类型; 第

四, 基于分割得到的形变参数, 将功能像标准化到蒙特利尔神经研究所 (MNI) 标准空间, 并重采样至 $3\times3\times3\text{ mm}^3$ 体素大小; 最后, 应用 8 mm 全宽半高 (FWHM) 的高斯核进行空间平滑, 以提高信噪比并满足统计分析的空间连续性假设。

2.3.3 任务激活的统计建模

研究采用 SPM12 软件进行基于体素的单变量激活分析。在个体水平分析中, 为每个被试构建一般线性模型 (GLM) 以估计各实验条件的激活强度。对于 n-back 工作记忆任务, 模型包含 0-back、1-back、2-back 三个任务条件以及基线条件; 停止信号任务包含成功执行试次、成功停止试次、基线条件以及错误试次; 任务转换范式则包含成功转换试次、成功重复试次、基线条件, 以及其他试次类型 (包括首试次、错误试次和错误后试次)。为控制头动相关的伪影, 将六个刚体运动参数作为协变量纳入模型。所有任务条件的时间序列均与标准血流动力学响应函数进行卷积, 并应用截止频率为 1/128 Hz 的高通滤波器以去除低频信号漂移。在此基础上设定关键实验对比: n-back 任务采用 "2-back > 0-back" 对比以反映工作记忆负荷效应; 停止信号任务采用 "成功停止 > 成功执行" 对比以捕获抑制控制过程; 任务转换范式采用 "成功转换 > 成功重复" 对比以量化认知灵活性成本。在组水平分析中, 对空间标准化后的统计图进行单样本 t 检验以获得群体水平推断 (Bougacha et al., 2024; Herault et al., 2024)。选择 $\alpha = 0.05$ 的显著性水平, 并采用 Bonferroni 校正方法控制家族错误率 (FWE), 对组水平统计图进行阈值处理。经阈值处理后的组水平统计图在后文中统称为统计图。统计推断使用 Python 的 Nilearn 工具包实施 (<https://nilearn.github.io>) (Abraham et al., 2014)。

2.4 大模型问答流程

本研究通过 OpenAI 官方商用 API 调用 GPT-4o ("Omnimodel") -2024-05-13 模型 (<https://platform.openai.com/docs/models>)。该模型在人机交互领域展现了较强的多模态理解和复杂推理能力。本研究将 temperature 参数设置为 0, 其他参数采用默认配置 (Coda-Forno et al., 2024; Cui et al., 2025; Kosinski, 2024; Suri et al., 2024)。研究采用提示词驱动的多轮对话范式, 模拟 AI 被试完成执行功能任务。为确保实验的生态效度和内部一致性, 所有执行功能任务在完整的单一对话上下

文中完成，保证各模拟被试之间的独立性。这种设计使模型能够在实验过程中维持一致的被试身份，并表现出类似人类的学习效应和反应模式 (Coda-Forno et al., 2024; Hu & Lewis, 2024; Kosinski, 2024; Suri et al., 2024)。为分析模型的认知过程，实验同步记录了模型输出每个 token 的对数概率参数(见 表 2)。Chat Completions API 的 logprobs 参数能够提供每个输出 token 的对数概率，以及每个 token 位置上最可能的候选 token 及其对数概率，这对评估模型输出置信度或检查可能的替代回答具有参考价值(Bauer et al., 2025)。

人类样本反映了执行功能的真实个体差异，而设置温度参数后的大语言模型响应主要产生围绕模型训练所决定的中心趋势的统计变异 (Cui et al., 2025)。由于大语言模型通常具有更均质的响应模式，统计效力的考量在基于大语言模型的重复研究中有所不同。生成过大的样本量可能产生伪精确性，违背了"当额外观测不会实质性改变推断时，数据收集成本可能超过收益"的价值信息原则 (Lakens, 2022)。此外，过大样本可能导致统计显著性被误解为实际意义 (Anvari & Lakens, 2021)。因此，针对数据集 1 (行为数据)，为 GPT-4o 生成 120 个模拟被试，用于评估 AI 与人类在执行功能效应上的差异，并探究对数概率参数与行为指标的关联。该样本量的选择基于效应检测能力的考虑：在 $\alpha = 0.05$ 、每组 $N = 120$ 的条件下，独立样本 t 检验对中等效应量 (Cohen's $d = 0.5$) 具有 90% 以上的统计效力，对大效应量 ($d = 0.8$) 具有 99% 以上的统计效力。执行功能研究中的典型效应量范围为 $d = 0.4-0.8$ (Karr et al., 2018)。此外，本研究采用逐试次的行为任务设计，每个被试完成多次重复试次，能够捕捉到稳定的行为模式。为确保与 AI 样本的公平比较并避免样本量不匹配导致的统计偏差，从数据集 1 的原始人类大样本 ($N = 1970$) 中随机抽取 120 名被试的子样本，与 AI 的 120 个样本进行配对比较。该策略控制了样本量差异对统计检验的影响，消除了因样本量差异产生的潜在替代解释。针对数据集 2 (fMRI 数据)，生成 39 个模拟被试与人类 fMRI 样本 ($N = 39$) 进行 1:1 匹配，用于探究模型内部状态参数与人脑激活模式的对应关系。每个 AI 模拟被试通过独立的对话会话完成数据集 2 的三项执行功能任务 (n -back 任务、停止信号任务、数字-字母类别转换任务)，生成方式与数据集 1 保持一致。

2.5 问答后的分析

2.5.1 大语言模型与人类执行功能对比分析

本研究采用贝叶斯层级线性模型 (Bayesian Hierarchical Linear Model) 分析 AI 与人类在执行功能效应上的差异 (见 补充表 1) (Miller et al., 2023), 通过贝叶斯因子 (Bayes Factor) 量化证据强度 (Kruschke & Liddell, 2018) (。分析在 Python 环境下使用 PyMC 包实现 (<https://www.pymc.io/welcome.html>)。模型采用弱信息先验 (weakly informative priors) 以允许数据主导推断 (Vehtari et al., 2017)。基于后验分布, 我们计算了一系列推断指标以全面评估 AI 与人类在执行功能上的差异。首先, 报告效应量差异的后验均值和中位数作为点估计。其次, 计算最高密度区间 (Highest Density Interval, HDI) 来表征参数的不确定性: 95% HDI 提供包含 95%最可信后验值的最窄区间。我们进一步计算贝叶斯因子,

$$BF_{10} = \frac{P(\Delta_{\text{effect}} > 0 | \text{data})}{P(\Delta_{\text{effect}} \leq 0 | \text{data})} = \frac{P(\text{positive})}{1 - P(\text{positive})},$$

用以量化支持"AI 效应大于人类"假设的证据强度。贝叶斯因子的解释遵循 Jeffreys (1961) 和 Kass & Raftery (1995) 的标准: $BF_{10} > 10$ 表示强证据支持备择假设, $3 < BF_{10} < 10$ 表示中等证据, $1 < BF_{10} < 3$ 表示弱证据, 而 $BF_{10} < 0.33$ 则表示证据支持零假设。此外, 为揭示大语言模型内部计算机制与外显行为的关联, 本研究对模型的任务表现与对数概率参数进行 Pearson 相关分析。具体分析了各执行功能任务的行为指标 (反应时或正确率) 与四类对数概率参数 (困惑度、对数概率方差、平均对数概率、最小对数概率) 之间的线性关系。采用 Benjamini-Hochberg 方法对所有相关系数进行 FDR 校正 ($\alpha = 0.05$) (Benjamini et al., 2001)。

2.5.2 大语言模型对数概率参数与脑区激活关联分析

为探究大语言模型的内部计算机制与人类脑活动的对应关系, 本研究将模型的对数概率参数变化与执行功能相关脑区的激活强度进行系统比较 (Doerig et al., 2025; Du et al., 2025)。使用 AAL (Automated Anatomical Labeling) 图谱的 116 个解剖学定义的脑区作为感兴趣区域 (ROI)。对每个被试, 从一级分析得到的任务对比图像 (如 n -back 任务"2-back > 0-back"对比) 中提取每个 ROI 的平均激

活值。首先，通过单样本 t 检验评估每个 ROI 的激活显著性，并采用 Bonferroni 校正控制多重比较 ($p_{\text{bonferroni}} < 0.05$)，筛选出显著激活的 ROI。然后，针对这些显著激活的 ROI，通过 Pearson 相关分析评估每个 ROI 的激活值与大语言模型对数概率参数之间的关联性，以识别与模型内部计算机制显著相关的脑区 (Chen et al., 2017; Fafrowicz et al., 2024)。

3 结果

3.1 GPT-4o 选择性复现人类执行功能的经典效应

3.1.1 干扰抑制：Stroop 色词任务

人类被试在 Stroop 任务中表现出典型的干扰效应。单因素方差分析显示 (见图 2A)，三种条件间的反应时存在显著差异 ($p = 0.001$, $\eta^2 = 0.038$)。事后比较表明，一致条件与中性条件之间无显著差异 ($p = 0.363$)，而不一致条件的反应时显著长于一致条件 ($p < 0.001$) 和中性条件 ($p = 0.009$)，呈现出经典的 Stroop 干扰效应。GPT-4o 在相同任务中表现出类似的干扰效应模式。单因素方差分析显示三种条件间反应时存在显著差异 ($p < 0.001$, $\eta^2 = 0.050$) (见图 2B)。具体而言，不一致条件的反应时显著长于一致条件 ($p < 0.001$) 和中性条件 ($p = 0.002$)，而一致条件与中性条件之间无显著差异 ($p = 0.384$)。值得注意的是，虽然人类和 GPT-4o 都表现出 Stroop 干扰效应，但效应强度存在明显差异。GPT-4o 的平均干扰效应 (89.210 ms) 高于人类 (51.570 ms)。贝叶斯分析进一步证实了这一差异，效应量差异的后验分布均值为 38.910 ms，95% HDI 为 [26.160, 52.620] ms。方向性检验表明，AI 干扰效应大于人类的后验概率为 100%，贝叶斯因子 $BF_{10} = \infty$ ，提供了强有力的证据支持 GPT-4o 表现出更强的干扰效应 (见图 2C)。

通过分析 GPT-4o 的输出概率分布，我们进一步探索了其内部加工过程。结果显示 (见图 2B)，困惑度在三种条件间存在显著差异 ($p < 0.001$, $\eta^2 = 0.119$)，其中不一致条件的困惑度显著高于一致条件 ($p < 0.001$) 和中性条件 ($p < 0.001$)。类似的模式也出现在对数概率方差 ($p < 0.001$, $\eta^2 = 0.088$)、平均对数概率 ($p < 0.001$, $\eta^2 = 0.126$) 和最小对数概率 ($p < 0.001$, $\eta^2 = 0.127$) 等指标上。这些指标

的一致性变化表明, GPT-4o 在处理不一致条件时经历了更高的决策不确定性和加工冲突。相关分析进一步揭示了行为表现与内部状态的关联 (见 图 2D)。GPT-4o 的反应时与困惑度呈正相关 ($r = 0.306, p < 0.001$), 与对数概率方差呈正相关 ($r = 0.280, p < 0.001$), 与平均对数概率呈负相关 ($r = -0.314, p < 0.001$), 与最小对数概率呈负相关 ($r = -0.272, p < 0.001$)。进一步的条件特异性分析显示, 在一致条件下, 反应时与困惑度 ($r = 0.339, p < 0.001$) 和对数概率方差 ($r = 0.404, p < 0.001$) 显著相关; 在不一致条件下, 反应时与困惑度 ($r = 0.358, p < 0.001$) 和平均对数概率 ($r = -0.383, p < 0.001$) 显著相关; 而在中性条件下, 所有相关均不显著 ($p > 0.050$)。

3.1.2 反应抑制: Go/No-Go 任务

人类被试在 Go/No-Go 任务中表现出典型的反应抑制困难, No-Go 试次的准确率显著低于 Go 试次 ($p < 0.001$) (见 图 3A)。相比之下, GPT-4o 在两种试次类型上均达到 100% 的准确率, 未表现出任何准确率差异 (见 图 3B)。贝叶斯分析显示, 抑制控制效应差异的后验分布均值为 0.110, 95% HDI 为 [0.086, 0.133]。方向性检验表明 (见 图 3C), AI 抑制控制效应小于人类的后验概率为 100%, $BF_{10} = \infty$, 表明 GPT-4o 的抑制控制能力与人类存在本质差异。尽管 GPT-4o 在行为准确率上达到完美表现, 其内部加工状态却呈现出不同的模式。分析发现, No-Go 试次的困惑度显著高于 Go 试次 ($p < 0.001, \eta^2 = 0.308$)。这种差异同样体现在对数概率方差 ($p < 0.001, \eta^2 = 0.211$)、平均对数概率 ($p < 0.001, \eta^2 = 0.308$) 和最小对数概率 ($p < 0.001, \eta^2 = 0.303$) 等指标上 (见 图 3B)。这些概率分布指标的系统性变化表明, 虽然 GPT-4o 在最终输出上实现了完美的抑制控制, 但在内部表征层面, No-Go 试次仍然引发了更高的决策不确定性和加工复杂度。

3.1.3 工作记忆容量: 数字正背与倒背任务

人类被试在数字广度任务中表现出经典的工作记忆容量特征, 正向数字广度显著高于倒背数字广度 ($p < 0.001$), 反映了倒背任务对工作记忆施加的额外认知负荷 (见 图 4A)。GPT-4o 同样表现出这一效应模式 ($p < 0.001$), 但其数字广度容量明显大于人类被试 (见 图 4B)。贝叶斯分析显示, 效应量差异的后验

分布均值为-2.830, 95% HDI 为[-3.660, -1.960]。方向性检验表明, AI 工作记忆效应小于人类的后验概率为 100%, 贝叶斯因子 BF_{10} 趋向于 0, 表明 GPT-4o 在倒背任务中经历了相对更大的性能下降 (见 图 4C)。

GPT-4o 的内部加工状态分析进一步揭示了任务难度对其认知加工的影响。困惑度在两种任务间存在显著差异 ($p < 0.001$), 倒背任务的困惑度显著高于正背任务。对数概率方差同样显示出显著差异 ($p < 0.001$), 倒背任务呈现更大的不确定性。平均对数概率 ($p < 0.001$) 和最小对数概率 ($p < 0.001$) 均显示 (见图 4B), 倒背任务中模型的预测置信度显著降低。相关分析揭示了任务复杂度的调节作用。在正背任务中, 序列长度与困惑度呈中等程度相关 ($r = 0.306, p < 0.001$), 与平均对数概率呈负相关 ($r = -0.307, p < 0.001$)。而在倒背任务中, 这些相关性明显增强: 序列长度与困惑度的相关达到 $r = 0.601$ ($p < 0.001$), 与平均对数概率的相关为 $r = -0.594$ ($p < 0.001$) (见 图 4D)。这种相关性的任务依赖性增强表明, 倒背任务中序列长度对认知负荷的影响更为显著。

3.1.4 工作记忆刷新: 数字活动记忆任务

人类被试在数字活动记忆任务中表现出典型的刷新时间效应, 在 1750ms 刺激呈现条件下的平均准确率显著高于 750ms 条件 ($p = 0.001$) (见 图 5A)。然而, GPT-4o 在两种条件下的表现无显著差异 ($p = 0.833$) (见 图 5B)。贝叶斯分析显示, 效应量差异的后验分布均值为-0.012, 95% HDI 为[-0.049, 0.020]。方向性检验表明, AI 更新效应小于人类的后验概率为 75.50% (见 图 5C), 贝叶斯因子 $BF_{01} = 3.090$, 提供了中等强度的证据支持 AI 在工作记忆刷新方面与人类存在不同的表现模式。有趣的是, GPT-4o 的内部加工状态分析显示出与行为表现相反的模式。困惑度在两种条件间存在显著差异 ($p = 0.002$), 750ms 条件下的困惑度反而低于 1750ms 条件 (见 图 5B)。平均对数概率 ($p = 0.002$) 和最小对数概率 ($p = 0.002$) 等指标也显示, 750ms 条件下模型呈现出更高的预测置信度。

3.1.5 认知灵活性: 数字转换任务

人类被试在数字转换任务中表现出经典的转换成本。混合任务转换条件下的反应时显著长于重复试次 (转换代价, $p < 0.001$) (见 图 6A), 混合任务重

复试次的反应时显著长于单任务（混合代价， $p < 0.001$ ）。GPT-4o 虽然也表现出显著的转换代价（ $p = 0.008$ ），但其幅度远小于人类（见 图 6B）。贝叶斯分析显示，转换代价差异的后验分布均值为-145.090 ms，95% HDI 为[-202.210, -90.730] ms。方向性检验表明（见 图 6C），AI 转换代价小于人类的后验概率为 100%，贝叶斯因子 $BF_{0:1}$ 趋向无穷大，提供了决定性证据支持 GPT-4o 的转换代价显著小于人类。尽管 GPT-4o 的转换代价极小，其混合代价仍然显著（58.190 ms），提示模型在混合任务情境中仍需要额外的计算资源。进一步的条件间比较显示，GPT-4o 在混合任务转换试次与重复试次间的反应时差异不显著（ $p = 0.958$ ），但混合任务条件与单任务条件间均存在显著差异（转换 vs 单任务： $p = 0.008$ ；重复 vs 单任务： $p = 0.009$ ）（见 图 6B）。与行为表现一致，GPT-4o 的内部加工状态分析未发现显著的条件间差异。困惑度在三种条件间无显著差异（所有 $p > 0.050$ ），对数概率方差和平均对数概率等指标同样未显示条件间的显著差异。

3.1.6 独立样本的执行功能任务验证

为验证上述发现的普遍性和稳健性，我们对数据集 2 中的三项任务进行了分析。在 *N*-Back 任务中（见 图 7A），LLMs 表现出典型的工作记忆负荷效应。随着 *N*-Back 水平的提高，准确率呈现系统性下降（0-back: 100%; 1-back: 93.2%; 2-back: 82.1%），单因素方差分析显示主效应显著（ $p < 0.001$ ）。事后比较表明，各条件间均存在显著差异：0-back 与 1-back（ $d = 2.850$ ）、0-back 与 2-back（ $d = 2.340$ ）以及 1-back 与 2-back（ $d = 1.380$ ）。反应时随工作记忆负荷增加而递增，尽管未达显著水平（ $p = 0.228$ ）。*N*-Back 效应分析显示，准确率下降 17.910%（ $p < 0.001$ ），反应时增加 3.050 ms（ $p < 0.001$ ）。这种准确率的显著下降配合反应时的小幅增加，表明 LLMs 在高工作记忆负荷下主要表现为准确性的损失而非速度的降低。内部状态参数随工作记忆负荷表现出系统性变化。困惑度和对数概率方差随负荷增加而降低，*N*-Back 效应分别为 -0.011 和 -0.005（均 $p < 0.001$ ）。平均对数概率和最小对数概率随负荷增加而变得更正（均 $p < 0.001$ ）。相关分析显示（见 图 7D），模型准确率与困惑度（ $r = 0.529, p_{fdr} < 0.001$ ）和对数概率方差（ $r = 0.534, p_{fdr} < 0.001$ ）呈正相关，与平均对数概率（ $r = -0.533, p_{fdr} < 0.001$ ）和最小对数概率（ $r = -0.587, p_{fdr} < 0.001$ ）呈负相关。反应时与内部状态参数的整体相关较弱（所

有 $p_{\text{fdr}} > 0.050$)，这种分离模式与数据集 1 的发现一致。

在停止信号任务中（见 图 7B），LLMs 表现出有效的反应抑制能力。Stop 成功试次相比 Go 成功试次，困惑度显著增加 ($p < 0.001, d = 0.880$)，对数概率方差更高 ($p = 0.002, d = 0.690$)。平均对数概率显著降低 ($p < 0.001, d = -0.870$)，最小对数概率表现出更负的值 ($p < 0.001, d = -1.030$)。所有四个内部状态参数在 Stop 成功与 Go 成功条件间的差异均达到中等到大的效应量，验证了抑制控制过程的认知需求。在字母数字转换任务中（见 图 7C），LLMs 未表现出人类典型的转换代价模式。反应时上几乎不存在转换代价（差值： -0.630 ms, $p = 0.228, d = 0.022$ ）。然而，内部状态参数揭示了显著的转换代价效应。困惑度在转换试次显著高于重复试次，产生 0.006 的转换代价 ($p < 0.001, d = 1.070$)。对数概率方差、平均对数概率和最小对数概率均表现出显著的转换代价（所有 $p < 0.001, d = 1.030-1.110$ ）。这种行为与内部状态的分离强调了 LLMs 独特的认知架构。

3.2 大语言模型对数概率参数与人脑神经活动的映射关系

在探究 LLMs 的行为表现后，我们进一步考察其内部计算参数是否与人脑神经活动存在对应关系。在停止信号任务的“成功停止 > 成功执行”对比分析中（见图 8A），未发现任何脑区的激活强度与大语言模型的内部计算参数存在显著相关，这可能反映了抑制控制在两个系统中的实现机制存在根本差异。在 n -back 工作记忆任务的“2-back > 0-back”对比分析中（见图 8B），我们发现了有意义的脑-模型对应关系。左侧直回的激活强度与模型的困惑度呈正相关 ($r = 0.340, p = 0.037$)，与平均对数概率呈负相关 ($r = -0.338, p = 0.038$)。右侧内侧额上回显示出类似的关联模式，其激活强度与困惑度呈正相关 ($r = 0.328, p = 0.044$)，与平均对数概率呈负相关 ($r = -0.325, p = 0.046$)。这些关联表明，工作记忆负荷增加时，人脑特定区域的激活模式与 LLMs 的内部不确定性变化存在对应关系。在任务转换范式的转换代价分析中（见图 8C），我们发现了大语言模型内部计算参数与皮层下结构激活之间的独特关联。左侧丘脑的激活强度与模型的最小对数概率呈正相关 ($r = 0.323, p = 0.048$)，而与困惑度呈负相关 ($r = -0.322, p = 0.048$)。这种与皮层下结构的关联可能反映了任务切换过程中的基础计算机制。

3.3 补充分析

为确保结果的稳健性并验证样本量的充分性, 我们进行了系统的重抽样分析 (见 补充图 2)。从原始人类大样本 ($N = 1970$) 中随机抽取 $N = 120$ 的子样本, 与 AI 的 120 个样本进行配对比较, 重复 3,000 次。在 *Stroop* 任务中, 99.8% 的迭代中观察到了显著的 *Stroop* 效应, 平均效应量 Cohen's $d = 0.372$, 95% CI [0.371, 0.374]。这一效应量与 GPT-4o 展现的效应量 ($d = 0.516$) 处于同一数量级, 表明 120 个样本足以稳定检测执行功能的核心效应。在 *Go/No-Go* 任务中, 所有迭代均观察到显著的 *Go/No-Go* 效应, 平均效应量 Cohen's $d = -0.866$, 95% CI [-0.870, -0.861]。人类被试表现出的抑制控制效应与 AI 样本量级相当, 验证了样本量的充分性。在工作记忆广度任务中, 所有迭代均发现显著的正序优势效应, 平均效应量 Cohen's $d = -0.701$, 95% CI [-0.705, -0.697]。人类被试的正背广度显著高于倒背广度, 与 GPT-4o 表现出的显著效应 ($d = -2.238$) 方向一致, 尽管效应量存在差异。在数字活动记忆任务中, 仅 37.8% 的迭代中观察到显著的时间效应, 平均效应量 Cohen's $d = -0.226$, 95% CI [-0.230, -0.223]。这一结果表明, 人类被试在该任务中的效应相对较弱, 而 GPT-4o 未表现出显著的工作记忆刷新效应 ($d = 0.027$), 两者的表现模式存在质的差异。在任务切换范式中, 所有迭代均检测到显著的切换成本, 平均效应量 Cohen's $d = 0.662$, 95% CI [0.659, 0.664]。切换成本在人类被试中表现稳定, 效应量显著大于 GPT-4o ($d = 0.347$)。这些补充分析不仅验证了主要发现的稳健性。

4 讨论

本研究系统评估了 GPT-4o 在模拟人类执行功能三个核心维度行为任务上的表现, 并探索了模型内部对数概率参数作为认知加工指标的可行性。研究发现, GPT-4o 在干扰抑制、工作记忆维持和刷新任务上复现了人类的典型认知效应, 但在反应抑制、时间压力下的工作记忆刷新以及认知灵活性任务上表现出与人类不同的模式。这种选择性复现现象揭示了当前大语言模型架构在模拟人类执行控制机制时的特定边界, 为理解执行功能的计算本质提供了新的实证依据。同时,

对数概率参数在特定任务情境下展现出作为认知加工评估工具的潜力,但其应用范围和解释框架仍需进一步验证。

4.1 大语言模型对执行功能的选择性复现

本研究发现 GPT-4o 能够有效复现涉及信息表征冲突和静态信息维持的执行功能效应。在 *Stroop* 任务中,模型在不一致条件下表现出显著的反应时延长,其效应量略大于人类被试的典型表现。这种增强的效应可能反映了语言模型作为计算系统的特点——不受疲劳、注意力波动等因素干扰,对冲突信息的处理更加系统化。这一发现与 Cui 等人 (2025) 的观察一致,他们发现语言模型倾向于产生更大的效应量和更窄的置信区间,在复现主效应时保持 79.7% 的方向一致性,但在交互效应上仅为 61.8%。本研究观察到的选择性复现模式印证了这一规律: GPT-4o 有效复现了涉及单一维度信息处理的基础效应,但在需要多维度交互或动态调节的任务上表现出明显差异。在工作记忆任务中, GPT-4o 表现出与人类相似的结构限制,但具体表现因任务性质而异。在数字广度任务中,模型复现了倒背困难效应,表明序列逆转对语言模型构成了额外的计算负荷,这与 Langis 等人 (2025) 在多个大语言模型上的发现一致。在 N-back 任务中, GPT-4o 表现出随负荷增加而递减的性能梯度,这一模式与人类工作记忆的经典发现相符。值得注意的是,虽然 Hu 和 Lewis (2024) 认为模型在 N-back 任务中的表现下降主要源于任务理解失败而非容量限制,但本研究发现 GPT-4o 能够正确理解任务要求并维持较高性能,这表明当任务理解不再是限制因素时,模型仍然表现出工作记忆的结构约束。

然而, GPT-4o 在涉及动态控制和时间敏感性的任务上未能展现人类的典型模式。在 Go/No-Go 和停止信号任务中,模型达到了完美的准确率,没有出现人类普遍存在的抑制失败现象。在工作记忆刷新任务中, GPT-4o 未表现出时间压力效应,而人类在该任务中表现出显著的刷新时间代价。工作记忆刷新要求在有限时间窗口内选择性更新部分信息同时保持其他信息不变,模型在这种时间敏感性任务上的表现差异提示,语言模型可能缺乏人类工作记忆系统的动态更新机制。在认知灵活性方面, GPT-4o 在转换试次和重复试次间几乎不存在性能差异,而

人类在任务转换时表现出稳定的反应时延长。这一发现与 Langis 等人 (2025) 在威斯康星卡片分类测试中的观察相似: 模型在适应变化的分类规则时表现不佳。这些结果共同反映了语言模型在认知灵活性上的局限。Cui 等人 (2025) 观察到的"零方差"现象——某些情况下语言模型产生完全一致的响应——进一步提示语言模型响应生成的高度确定性特征, 而这种变异性的缺乏可能恰恰是执行控制机制正常运作所必需的。

本研究的选择性复现模式为理解 Miyake 三因子模型提供了新的计算视角, 提示执行功能各子成分内部可能存在计算异质性。不同任务虽然表面上测量相同的执行功能维度, 但可能涉及计算本质不同的认知过程。例如, Stroop 任务和 Go/No-Go 任务都被认为测量抑制控制, 但前者能够被语言模型复现而后者不能, 这表明两者涉及的抑制机制在计算层面存在根本差异。语言模型能够复现基于符号表征和静态维持的过程, 但在需要动态控制、时间敏感性或内在变异性的过程上表现出根本性差异。这种计算异质性可能有助于解释执行功能因子结构在不同研究中存在变异的原因 (Karr et al., 2018)。通过系统比较模型与人类的行为模式, 我们能够识别哪些认知过程可以通过大规模文本学习获得, 哪些则依赖于人类特有的生物结构或具身经验。

4.2 对数概率参数作为认知加工内部指标的可能性

当前关于大语言模型认知表现的研究主要聚焦于行为输出层面, 缺乏对模型内部计算过程的系统探究。本研究将 GPT-4o 的对数概率参数引入执行功能评估, 不仅关注任务准确率和反应时, 还通过内部状态参数分析揭示其认知加工机制, 为评估大语言模型的认知能力提供了新的分析框架。研究发现, 对数概率参数与行为表现之间存在系统性但任务特异的关联。在 Stroop 任务中, 反应时与困惑度呈显著正相关, 与平均对数概率呈显著负相关。这种关联在不一致条件下尤为明显, 表明当模型面临语义冲突时, 内部不确定性的增加直接反映在行为延迟上。类似模式也出现在数字广度任务中: 倒背条件下序列长度与困惑度的相关远高于正背条件, 揭示了认知负荷对内部计算状态的调节作用。

然而, 这种关联并非普遍存在。在任务转换范式中, 尽管行为层面几乎不存

在转换代价，内部状态参数却显示出显著的条件差异。这种行为-内部状态分离现象在 *N-back* 任务中也有体现，提示对数概率参数可能捕捉到了传统行为指标未能反映的认知加工过程。在行为表现达到天花板效应的任务中，内部参数仍能揭示认知加工的差异。例如，在 *Go/No-Go* 任务中，虽然 GPT-4o 达到完美准确率，但 No-Go 试次的困惑度显著高于 Go 试次，平均对数概率显著更低，表明模型在内部表征层面仍经历了抑制冲突的加工过程。这种现象具有重要的理论意义。Coda-Forno 等人 (2024) 观察到语言模型表现出"难以改变的强偏差"，本研究的发现进一步表明，这种偏差可能不总是体现在行为输出上，而是反映在内部计算过程中。统计不确定性的增加不必然导致外显行为代价，这揭示了语言模型与人类认知系统在信息处理层级结构上的差异。

为验证对数概率参数作为认知指标的生物学合理性，我们探索了其与人脑神经活动的对应关系。在 *N-back* 任务中，左侧直回和右侧内侧额上回的激活强度与模型困惑度呈显著正相关，与平均对数概率呈负相关。这些脑区是工作记忆网络的关键节点，其激活模式与模型内部状态的对应关系提示了某种功能等价性。在任务转换范式中，左侧丘脑激活与最小对数概率呈正相关，与困惑度呈负相关。丘脑作为认知控制网络的核心结构，其激活模式与模型内部参数的关联表明，对数概率参数可能捕捉到了类似的控制加工过程。然而，在停止信号任务中未发现显著的脑-模型参数相关。这一结果与该任务中模型表现出的完美准确率相呼应，提示对数概率参数与人脑激活的对应关系具有任务特异性。当模型的计算策略与人类认知过程存在根本性差异时，即使内部参数显示出条件差异，也未必能够映射到人脑的神经活动模式上。Doerig 等人 (2025) 提出，通过分析哪些任务存在模型-大脑对应、哪些不存在，可以反推人脑与人工智能的计算共性与差异。本研究的结果支持这一观点：对数概率参数与人脑激活的对应关系主要出现在模型能够成功复现人类行为模式的任务中，而在模型表现出根本性差异的任务中则不存在这种对应。

综合来看，对数概率参数作为认知加工的内部指标展现出重要价值。首先，相比深度神经网络的隐藏层激活，对数概率参数具有明确的统计学意义，使其心理学解释更加直观。困惑度可以理解为认知负荷的指标，对数概率方差可以反映

加工稳定性。其次，OpenAI 等公司通过 API 接口开放对数概率参数，研究者无需访问模型权重或训练数据即可进行分析，降低了使用大语言模型进行认知研究的技术门槛。

4.3 研究启示

4.3.1 对理解执行功能计算本质的理论启示

本研究通过大语言模型这一计算工具，为执行功能的计算本质提供了独特视角。选择性复现模式揭示了各执行功能成分内部可能存在的计算异质性，为理解 Miyake 三因子模型中不同任务间的关系提供了新的理论依据。传统研究通过因子分析方法探索任务间的共变关系，而本研究通过比较哪些任务能够被语言模型复现、哪些不能，从计算机制的角度揭示了任务间的本质差异。这种研究策略的价值在于，它能够超越相关性分析，探究因果性的计算机制。语言模型的选择性复现帮助我们识别了执行功能中哪些成分可能基于领域通用的计算原理，哪些则可能需要特定的神经生物学基础。这一发现无法从传统的人类被试研究中直接获得，因为人类被试同时拥有多种认知机制，难以分离各自的贡献。

4.3.2 为大语言模型认知评估提供方法学框架

本研究为大语言模型的认知能力评估提供了新的方法学框架。传统评估主要关注任务准确率，本研究引入了三个层次的分析：行为表现层面的准确率和反应时、内部状态层面的对数概率参数、以及脑-模型对应层面的神经相关性。这种多层次分析框架能够更全面地刻画模型的认知特征，避免单纯依赖行为表现可能导致的误判。例如，在 *Go/No-Go* 任务中，如果仅看行为表现，可能会得出"GPT-4o 具有完美的反应抑制能力"的结论。但内部参数分析显示模型仍经历了抑制冲突，而脑-模型相关分析显示这种内部状态与人脑反应抑制网络并无对应关系。这三个层次的证据共同表明，模型的"完美表现"并非源于人类意义上的反应抑制能力，而是其不同的计算机制所致。Bauer 等人（2025）提出了使用对数概率参数评估语言模型不确定性的方法，本研究将这一方法拓展到认知心理学领域，验证了其在执行功能评估中的应用价值。未来研究可以进一步探索其他内部参数（如注意

力权重、隐藏层激活) 与认知加工的关系, 建立更加完善的认知评估工具箱。

4.4 局限性与未来展望

尽管本研究获得了有意义的发现, 但仍存在一些局限性。首先, 本研究聚焦于 GPT-4o 这一特定模型。不同模型架构、规模和训练范式可能导致不同的执行功能表现。例如, 经过更多人类反馈强化学习训练的模型可能在遵循"抑制指令"方面表现更好, 但这是否意味着它们真正"获得了反应抑制能力"还需要进一步探讨。本研究的选择性复现模式可能部分反映了 GPT 系列模型的特定特征, 未来研究应该在多个主流模型上重复评估, 建立大语言模型执行功能的基准数据集。其次, 虽然本研究基于 Miyake 框架覆盖了执行功能三大成分, 但每个成分仅包含有限任务。执行功能的完整评估需要更广泛的范围, 包括 Simon 任务、复杂广度任务、威斯康星卡片分类任务等。未来研究应扩展任务范围, 更全面地绘制大语言模型的执行功能图谱。此外, 本研究初步验证了对数概率参数作为认知指标的潜力, 但仍有诸多问题有待解决。在参数选择与组合方面, API 还提供其他信息如 *top-k token* 的概率分布, 哪些参数组合最能预测认知表现需要进一步探索。对数概率参数的心理学意义是否在不同模型间保持一致也需要验证。本研究主要基于相关性分析, 未来可以尝试操纵对数概率参数, 观察行为表现的相应变化, 建立因果联系。最后, 关于选择性复现背后的理论机制还需要深入探讨。为什么某些执行功能成分能够通过文本学习获得而其他不能? 这种差异是否反映了认知功能的进化层级? 这些问题的回答将有助于我们更深入地理解人类认知的独特性和人工智能的发展方向。

5 结论

本研究系统评估了 GPT-4o 在一系列执行功能任务中的表现。结果表明, 该模型在干扰抑制、工作记忆容量限制以及工作记忆刷新等任务中成功复现了人类的典型认知模式, 但在反应抑制、时间压力条件下的工作记忆刷新以及认知灵活性任务中未能展现出人类的行为特征。这种系统性的表现差异提示, 当前的大语言模型能够较好地模拟基于符号表征和静态信息维持的认知过程, 但在涉及动态控制、时间敏感性处理或需要内在变异性的认知任务上仍存在明显的局限。研究

548 发现, 对数概率参数作为模型内部状态的量化指标, 在部分任务中与行为表现和
549 人脑激活模式呈现出系统性关联, 这为认知加工的评估提供了新的分析视角。未
550 来研究应在更广泛的模型架构上进行重复验证, 扩展任务范围以涵盖更多执行功
551 能的子成分, 并深入探究对数概率参数与模型内部机制(如注意力权重分布)之间
552 的关系。
553
554

参考文献

- Abraham, A., Pedregosa, F., Eickenberg, M., Gervais, P., Mueller, A., Kossaifi, J., Gramfort, A., Thirion, B., & Varoquaux, G. (2014). Machine learning for neuroimaging with scikit-learn. *Frontiers in Neuroinformatics*, 8, 14. <https://doi.org/10.3389/fninf.2014.00014>
- Anvari, F., & Lakens, D. (2021). Using anchor-based methods to determine the smallest effect size of interest. *Journal of Experimental Social Psychology*, 96, 104159. <https://doi.org/10.1016/j.jesp.2021.104159>
- Aron, A. R., Robbins, T. W., & Poldrack, R. A. (2014). Inhibition and the right inferior frontal cortex: One decade on. *Trends in Cognitive Sciences*, 18(4), 177–185. <https://doi.org/10.1016/j.tics.2013.12.003>
- Bauer, C., Duc Dang, L. T., van den Beucken, T., Schuchhardt, J., & Herwig, R. (2025). Systematic analysis of hepatotoxicity: Combining literature mining and AI language models. *Frontiers in Artificial Intelligence*, 8. <https://doi.org/10.3389/frai.2025.1561292>
- Benjamini, Y., Drai, D., Elmer, G., Kafkafi, N., & Golani, I. (2001). Controlling the false discovery rate in behavior genetics research. *Behavioural Brain Research*, 125(1), 279–284. [https://doi.org/10.1016/S0166-4328\(01\)00297-2](https://doi.org/10.1016/S0166-4328(01)00297-2)
- Binz, M., Akata, E., Bethge, M., Brändle, F., Callaway, F., Coda-Forno, J., Dayan, P., Demircan, C., Eckstein, M. K., Éltető, N., Griffiths, T. L., Haridi, S., Jagadish, A. K., Ji-An, L., Kipnis, A., Kumar, S., Ludwig, T., Mathony, M., Mattar, M., ... Schulz, E. (2025). A foundation model to predict and capture human cognition. *Nature*, 1–8. <https://doi.org/10.1038/s41586-025-09215-4>
- Botvinick, M. M., Braver, T. S., Barch, D. M., Carter, C. S., & Cohen, J. D. (2001). Conflict monitoring and cognitive control. *Psychological Review*, 108(3), 624. <https://doi.org/10.1037/0033-295X.108.3.624>
- Bougacha, S., Roquet, D., Landeau, B., Saul, E., Naveau, M., Sherif, S., Bejanin, A., Dhenain, M., Raj, A., Vivien, D., Chetelat, G., & Initiative, for the A. D. N. (2024). Contributions of connectional pathways to shaping Alzheimer's disease pathologies. *Brain Communications*, 7(1). <https://doi.org/10.1093/braincomms/fcae459>
- Chemero, A. (2023). LLMs differ from human cognition because they are not embodied. *Nature Human Behaviour*, 7(11), 1828–1829. <https://doi.org/10.1038/s41562-023-01723-5>
- Chen, X., Zhang, H., Zhang, L., Shen, C., Lee, S.-W., & Shen, D. (2017). Extraction of dynamic functional connectivity from brain grey matter and white matter for MCI classification. *Human Brain Mapping*, 38(10), 5019–5034. <https://doi.org/10.1002/hbm.23711>
- Coda-Forno, J., Binz, M., Wang, J. X., & Schulz, E. (2024). *CogBench: A large language model walks into a psychology lab* (20 citation(s); No. arXiv:2402.18225). arXiv. <https://doi.org/10.48550/arXiv.2402.18225>
- Cui, Z., Li, N., & Zhou, H. (2025). A large-scale replication of scenario-based experiments in psychology and management using large language models. *Nature Computational Science*, 5(8), 627–634. <https://doi.org/10.1038/s43588-025-00840-7>
- D'Esposito, M., & Postle, B. R. (2015). The cognitive neuroscience of working memory. *Annual Review of Psychology*, 66, 115.

-
- Diamond, A. (2013). Executive Functions. *Annual Review of Psychology*, 64(1), 135–168.
<https://doi.org/10.1146/annurev-psych-113011-143750>
- Doerig, A., Kietzmann, T. C., Allen, E., Wu, Y., Naselaris, T., Kay, K., & Charest, I. (2025). High-level visual representations in the human brain are aligned with large language models. *Nature Machine Intelligence*, 1–15.
- Du, C., Fu, K., Wen, B., Sun, Y., Peng, J., Wei, W., Gao, Y., Wang, S., Zhang, C., Li, J., Qiu, S., Chang, L., & He, H. (2025). Human-like object concept representations emerge naturally in multimodal large language models. *Nature Machine Intelligence*, 7(6), 860–875.
<https://doi.org/10.1038/s42256-025-01049-z>
- Fafrowicz, M., Tutajewski, M., Sieradzki, I., Ochab, J. K., Ceglarek-Sroka, A., Lewandowska, K., Marek, T., Sikora-Wachowicz, B., Podolak, I. T., & Oświęcimka, P. (2024). Classification of ROI-based fMRI data in short-term memory tasks using discriminant analysis and neural networks. *Frontiers in Neuroinformatics*, 18. <https://doi.org/10.3389/fninf.2024.1480366>
- Frank, M. C. (2023). Openly accessible LLMs can help us to understand human cognition. *Nature Human Behaviour*, 7(11), 1825–1827. <https://doi.org/10.1038/s41562-023-01732-4>
- Friedman, N. P., & Robbins, T. W. (2022). The role of prefrontal cortex in cognitive control and executive function. *Neuropsychopharmacology*, 47(1), 72–89.
<https://doi.org/10.1038/s41386-021-01132-0>
- Gong, D., Wan, X., & Wang, D. (2024). Working Memory Capacity of ChatGPT: An Empirical Study. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(9), 10048–10056.
<https://doi.org/10.1609/aaai.v38i9.28868>
- Hagendorff, T., Fabi, S., & Kosinski, M. (2023). Human-like intuitive behavior and reasoning biases emerged in large language models but disappeared in ChatGPT. *Nature Computational Science*, 3(10), 833–838. <https://doi.org/10.1038/s43588-023-00527-x>
- He, L., Zhuang, K., Chen, Q., Wei, D., Chen, X., Fan, J., & Qiu, J. (2021). Unity and diversity of neural representation in executive functions. *Journal of Experimental Psychology: General*, 150(11), 2193–2207. <https://doi.org/10.1037/xge0001047>
- Herault, C., Ovando-Tellez, M., Lebeda, I., Kenett, Y. N., Beranger, B., Benedek, M., & Volle, E. (2024). Creative connections: The neural correlates of semantic relatedness are associated with creativity. *Communications Biology*, 7(1), 810.
<https://doi.org/10.1038/s42003-024-06493-y>
- Hu, X., & Lewis, R. L. (2024). *Do Language Models Understand the Cognitive Tasks Given to Them? Investigations with the N-Back Paradigm* (No. arXiv:2412.18120). arXiv.
<https://doi.org/10.48550/arXiv.2412.18120>
- Karr, J. E., Areshenkoff, C. N., Rast, P., Hofer, S. M., Iverson, G. L., & Garcia-Barrera, M. A. (2018). The unity and diversity of executive functions: A systematic review and re-analysis of latent variable studies. *Psychological Bulletin*, 144(11), 1147–1185.
<https://doi.org/10.1037/bul0000160>
- Ke, L., Tong, S., Cheng, P., & Peng, K. (2025). Exploring the frontiers of LLMs in psychological applications: A comprehensive review. *Artificial Intelligence Review*, 58(10), 305.
<https://doi.org/10.1007/s10462-025-11297-5>
- Kosinski, M. (2024). Evaluating large language models in theory of mind tasks. *Proceedings of*

-
- the *National Academy of Sciences*, 121(45), e2405460121.
<https://doi.org/10.1073/pnas.2405460121>
- Kruschke, J. K., & Liddell, T. M. (2018). The Bayesian New Statistics: Hypothesis testing, estimation, meta-analysis, and power analysis from a Bayesian perspective. *Psychonomic Bulletin & Review*, 25(1), 178–206. <https://doi.org/10.3758/s13423-016-1221-4>
- Lakens, D. (2022). Sample Size Justification. *Collabra: Psychology*, 8(1), 33267. <https://doi.org/10.1525/collabra.33267>
- Langis, K. de, Park, J. I., Hu, B., Le, K. C., Schramm, A., Mensink, M. C., Elfenbein, A., & Kang, D. (2025). *A Framework for Robust Cognitive Evaluation of LLMs* (No. arXiv:2504.02789). arXiv. <https://doi.org/10.48550/arXiv.2504.02789>
- Loconte, R., Orrù, G., Tribastone, M., Pietrini, P., & Sartori, G. (2023). *Challenging ChatGPT ' Intelligence' with Human Tools: A Neuropsychological Investigation on Prefrontal Functioning of a Large Language Model* (13 citation(s); SSRN Scholarly Paper No. 4377371). Social Science Research Network. <https://doi.org/10.2139/ssrn.4377371>
- Meng, J. (2024). AI emerges as the frontier in behavioral science. *Proceedings of the National Academy of Sciences*, 121(10), e2401336121. <https://doi.org/10.1073/pnas.2401336121>
- Miller, E. J., Steward, B. A., Witkower, Z., Sutherland, C. A., Krumhuber, E. G., & Dawel, A. (2023). AI hyperrealism: Why AI faces are perceived as more real than human ones. *Psychological Science*, 34(12), 1390–1403. <https://doi.org/10.1177/09567976231207095>
- Miyake, A., & Friedman, N. P. (2012). The nature and organization of individual differences in executive functions: Four general conclusions. *Current Directions in Psychological Science*, 21(1), 8–14. <https://doi.org/10.1177/0963721411429458>
- Suri, G., Slater, L. R., Ziaee, A., & Nguyen, M. (2024). Do large language models show decision heuristics similar to humans? A case study using GPT-3.5. *Journal of Experimental Psychology: General*, 153(4), 1066–1075. <https://doi.org/10.1037/xge0001547>
- Valmeekam, K., Olmo, A., Sreedharan, S., & Kambhampati, S. (2022, November 18). *Large Language Models Still Can't Plan (A Benchmark for LLMs on Planning and Reasoning about Change)*. NeurIPS 2022 Foundation Models for Decision Making Workshop. <https://openreview.net/forum?id=wUU-7XTL5XO>
- Vehtari, A., Gelman, A., & Gabry, J. (2017). Practical Bayesian model evaluation using leave-one-out cross-validation and WAIC. *Statistics and Computing*, 27(5), 1413–1432. <https://doi.org/10.1007/s11222-016-9696-4>
- Yan, C.-G., Wang, X.-D., Zuo, X.-N., & Zang, Y.-F. (2016). DPABI: data processing & analysis for (resting-state) brain imaging. *Neuroinformatics*, 14(3), 339–351. <https://doi.org/10.1007/s12021-016-9299-4>
- Zhang, C., Jian, Y., Ouyang, Z., & Vosoughi, S. (2024). Working Memory Identifies Reasoning Limits in Language Models. In Y. Al-Onaizan, M. Bansal, & Y.-N. Chen (Eds.), *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing* (pp. 16896–16922). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2024.emnlp-main.938>

679 表 1 被试人口学信息

	数据集 1 (N = 1970)	数据集 2 (N = 39)
年龄	19.78±1.72	19.21±0.52
性别		
男	915 (46.45%)	13 (33.3%)
女	1055 (53.55%)	26 (66.7%)
执行功能测量	Stroop 色词任务	n-back 任务
任务范式	Go/No-Go 任务	停止信号任务
	数字转换任务	数字-字母类别转换任务
	活动记忆任务	
	数字正背和倒背任务	
MRI 数据采集	/	有
数据采集地区	中国 甘肃省	中国 重庆市

680

681

表 2 对数概率参数说明

参数名称	含义	计算方式	高数值意味着	认知类比
Perplexity	困惑度：模型对序列的"惊讶程度"或不确定性	$2^{(-\text{平均对数概率})}$	模型很困惑，不确定答案	人类面对难题时的"纠结程度"
Logprob Variance	对数概率方差：模型在不同词元选择上的一致性	各词元对数概率的方差	选择时摇摆不定，不一致	思考时的"稳定性"
Avg Logprob	平均对数概率：模型对整个序列的平均置信度	所有词元对数概率的均值	整体置信度高	对答案的"总体信心"
Min Logprob	最小对数概率：序列中最不确定的那个词元	所有词元中最小的对数概率	存在高度不确定的选择	选答案中"最薄弱的环节"


注：对数概率参数通过 OpenAI API 获取 (<https://platform.openai.com/docs/api-reference/chat/create>)，反映大语言模型在执行任务时的不确定性、困惑度和决策置信度，可类比为人类认知过程中的神经活动指标。这些参数为理解 AI 系统的"认知"过程提供了可量化的行为指标。

682


683

684


Step 1. Executive Function Assessments from Humans and Large Language Models



Step 2. Bayesian Difference Testing and Logprobs Parameters Correlation Analysis



Step 3. Correlational Analysis between Logprobs Parameters and ROI Activation



685 图 1 实验设计流程图

686 注：本研究包括三个主要步骤。步骤一： 数据采集与模型测试。收集数据集 1 中人类被试 ($N = 1,970$) 完
 687 成五项执行功能任务的行为数据，同时通过提示词驱动的多轮对话范式让 GPT-4o 模拟被试 ($N = 120$) 完
 688 成相同任务，并提取模型输出的逐词元对数概率参数（包括困惑度、对数概率方差、平均对数概率、最小
 689 对数概率）作为其内部计算状态的量化指标。步骤二： 行为数据分析。采用贝叶斯层级线性模型检验 GPT-4o

能否复现人类在执行功能任务中的经典认知效应（如 *Stroop* 干扰效应、任务转换代价等）。为确保统计稳健性和公平比较，从人类全样本中进行 3,000 次自助法重采样，每次随机抽取 120 名被试以匹配 AI 样本量，通过贝叶斯因子量化 AI 与人类效应差异的证据强度。同时，通过 Pearson 相关分析（FDR 校正）探究模型对数概率参数与行为指标的关联性，揭示模型内部计算机制与外显行为的对应关系。步骤三：脑成像数据分析。采集数据集 2 中被试（N = 39）完成三项执行功能任务（*n*-back 任务、停止信号任务、数字-字母类别转换任务）时的功能磁共振成像数据。通过一般线性模型进行个体水平激活分析，设定关键任务对比，提取 AAL 图谱定义的 116 个脑区的平均激活值。针对显著激活的脑区，通过 Pearson 相关分析检验各脑区激活强度与 GPT-4o 对数概率参数的关联性。




图 2 Stroop 色词任务中大语言模型与人类被试的行为表现比较

注: (A) 人类被试在 Stroop 任务三种条件下的反应时比较 (N=120)。(B) GPT-4o 在 Stroop 任务三种条件下的反应时及对数概率参数比较。(C) 人类与 GPT-4o 干扰效应 (不一致条件减去一致条件) 的贝叶斯分析比较。(D) GPT-4o 在 Stroop 任务三种条件下反应时与对数概率参数的相关分析。




图 3 Go/No-Go 任务中大语言模型与人类被试的反应抑制表现比较

注: (A) 人类被试在 Go/No-Go 任务中 Go 试次和 No-Go 试次的准确率比较 (N=120)。(B) GPT-4o 在 Go/No-Go 任务中的准确率及对数概率参数比较。(C) 人类与 GPT-4o 抑制控制效应 (No-Go 准确率减去 Go 准确率) 的贝叶斯分析比较。




图 4 数字广度任务中大语言模型与人类被试的工作记忆容量表现比较

注: (A) 人类被试在数字正背和倒背任务中的记忆广度比较 ($N=120$)。 (B) GPT-4o 在数字正背和倒背任务中的记忆广度及对数概率参数比较。 (C) 人类与 GPT-4o 工作记忆效应 (正背广度减去倒背广度) 的贝叶斯分析比较。 (D) GPT-4o 在数字正背和倒背任务中序列长度与对数概率参数的相关分析。




图 5 数字活动记忆任务中大语言模型与人类被试在不同刺激呈现时间条件下的表现比较

注: (A) 人类被试在数字活动记忆任务不同刺激呈现时间 (1750ms 和 750ms) 条件下的准确率比较 ($N=120$)。 (B) GPT-4o 在两种刺激呈现时间条件下的准确率及对数概率参数比较。 (C) 人类与 GPT-4o 刷新时间效应 (750ms 条件准确率减去 1750ms 条件准确率) 的贝叶斯分析比较。




图 6 数字转换任务中大语言模型与人类被试的任务转换代价比较

注：(A) 人类被试在数字转换任务中的转换代价和混合代价比较 ($N=120$)。 (B) GPT-4o 在数字转换任务三种条件下的反应时及对数概率参数比较。 (C) 人类与 GPT-4o 转换代价的贝叶斯分析比较。








图 7 数据集 2 中三项执行功能任务的行为表现

注: (A) 人类被试与 GPT-4o 在 n -back 任务中的表现比较。(B) 人类被试与 GPT-4o 在停止信号任务中的表现比较。(C) 人类被试与 GPT-4o 在数字-字母类别转换任务中的表现比较。(D) GPT-4o 在 2-back 任务中行为表现与对数概率参数的相关分析。

A Stop-signal task (assessing inhibitory control)



B Switching task (assessing cognitive flexibility)



C n-back task (assessing working memory)





图 8 大语言模型内部状态与人脑神经活动的对应关系分析

注：(A) 停止信号任务（评估反应抑制）。左图为人脑激活模式，显示“成功停止>成功执行”对比的组水平统计图（Bonferroni校正， $p < 0.05$ ）；右图显著激活脑区（基于 AAL 图谱的 116 个 ROI）的平均激活值与 GPT-4o 对数概率参数的相关性分析结果。(B) 数字-字母类别转换任务（评估认知灵活性）。左图“成功转换>成功重复”对比的脑激活模式；右图显著激活脑区与模型参数的相关性分析。(C) n -back 任务（评估工作记忆）。左图“2-back>0-back”对比的脑激活模式；右图显著激活脑区与模型参数的相关性分析。

Supplemented materials

Supplementary Methods

Executive function assessments

Stroop Color-Word Task: We administered the Stroop color-word task to assess interference control (Jensen & Rohwer Jr, 1966). The task used two Chinese color characters ("红" [red] and "绿" [green]) and a neutral string ("#####") as stimuli. Participants indicated the ink color by pressing "F" for red and "J" for green. Three conditions were included: congruent (character "红" in red ink and "绿" in green ink), incongruent (character "绿" in red ink and "红" in green ink), and neutral (string "#####" in red or green ink). Each trial began with a 500-ms fixation cross, followed by a 1000-ms blank screen and a 1500-ms stimulus presentation, then an inter-trial interval. Following one practice block (18 trials with feedback), participants completed three experimental blocks only after achieving $\geq 85\%$ accuracy and receiving experimenter approval. Each experimental block contained 36 trials (12 per condition), totaling 108 trials. The task required approximately 15 minutes, with rest periods between blocks.

Go/No-Go Task: Response inhibition was measured using the Go/No-Go task (Gomez et al., 2007). Letters X and Y were presented randomly, with participants responding to target stimuli (Go trials) while withholding responses to non-target stimuli (No-Go trials). After two practice blocks (10 Go and 10 No-Go trials each) with feedback, participants achieving $\geq 85\%$ accuracy proceeded to four experimental blocks (50 Go and 50 No-Go trials each). Each trial displayed a 1000-ms fixation cross, followed by a 600-ms stimulus and an inter-trial interval. In two blocks, participants pressed "J" for X (Go) and withheld responses for Y (No-Go); in the other two blocks, these instructions were reversed. The task lasted approximately 15 minutes with rest periods between blocks.

Number-Switching Task: Cognitive flexibility was assessed using the number-switching task (Kray et al., 2002), which alternated between magnitude

judgment (Task A) and parity judgment (Task B). In Task A, participants classified red numbers (1-9, excluding 5) as smaller ("A" key) or larger ("L" key) than 5. In Task B, participants classified blue numbers (1-9, excluding 5) as odd ("A" key) or even ("L" key). The experiment comprised 20 blocks: 10 single-task blocks (8 trials each) and 10 mixed-task blocks (17 trials each), totaling 250 trials, presented in randomized order. After achieving $\geq 75\%$ accuracy in two single-task practice blocks, participants proceeded to the experimental phase. Each block began with a fixation cross, followed by stimulus presentation until response, with a 25-ms inter-trial interval. Response key assignments were counterbalanced across pre- and post-test sessions. The task lasted approximately 15 minutes with rest periods between blocks.

Running Memory Task: Working memory updating was assessed using the running memory task (Zhao et al., 2022). The task included simple (1750-ms digit presentation) and difficult (750-ms digit presentation) conditions. Random digit sequences (0-9) of varying lengths (5, 7, 9, or 11 digits) were presented serially. Participants continuously updated their memory to recall the three most recent digits in order. For instance, given "6, 8, 5, 4, 7, 2", participants updated their memory as: 6→6-8→6-8-5→8-5-4→5-4-7→4-7-2, then entered "4-7-2". The simple condition included one practice block (8 trials) and two experimental blocks (12 trials each). The difficult condition included two experimental blocks (12 trials each). Working memory updating was indexed by mean accuracy across both conditions. The task required approximately 20 minutes with rest periods between blocks.

Digit Span Forward and Backward task: Working memory maintenance was measured using digit span tasks (Zhao et al., 2022). Random digit sequences (0-9) were presented serially (1000 ms per digit). For the backward task, participants recalled sequences in reverse order (e.g., "1-2-3" recalled as "3-2-1"). Both forward and backward tasks followed identical procedures. Starting with three-digit sequences, participants completed three trials per difficulty level. Sequence length increased by one digit when at least two of three sequences were correctly recalled; otherwise, the task terminated. Working memory maintenance was indexed by the maximum sequence length successfully recalled.

n-Back Task: The digit *n*-back task included three conditions (0-back, 1-back,

and 2-back) presented in a block design. In the 0-back condition, participants detected whether the current item was "1". In 1-back and 2-back conditions, participants detected whether the current item matched the item presented one or two positions earlier, respectively. Each condition contained four blocks. Each 29-second block included a 2-second task prompt followed by 15 single-digit stimuli (400-ms presentation, 1400-ms inter-stimulus interval). Participants had 1400 ms to respond to target stimuli. Blocks were separated by 6-second intervals and presented in pseudorandom order with no more than three consecutive repetitions of the same condition.

Stop-Signal Task: The stop-signal task comprised 32 stop trials and 96 go trials. Each trial began with a 300-ms fixation cross, followed by a left- or right-pointing green arrow. For go trials, the green arrow appeared for 500 ms. Participants pressed "1" (left arrow) or "2" (right arrow) within 1500 ms, followed by a 700-ms blank screen. For stop trials, after a stop-signal delay (SSD), a red arrow appeared for 300 ms, signaling participants to inhibit their response. The initial SSD was 250 ms and adjusted dynamically: successful inhibition increased the subsequent SSD by 50 ms, while failed inhibition decreased it by 50 ms. A blank screen followed for 1200 ms minus the SSD duration. Inter-trial intervals varied from 1-4 seconds (mean = 2.5 seconds).

Letter-Number Category-Switching Task: The switching task included 48 repeat trials and 48 switch trials. Each trial began with a 1000-ms fixation cross, followed by a number-letter or letter-number pair presented for 2500 ms. When letters appeared in red, participants judged whether numbers were odd or even; when letters appeared in green, participants judged whether letters were consonants or vowels. Participants pressed "1" for odd numbers and consonants or "2" for even numbers and vowels within 2500 ms. Inter-trial intervals ranged from 1-4 seconds (mean = 2.5 seconds). Trials requiring the same judgment as the previous trial were classified as repeat trials (after the first trial); otherwise, they were switch trials. Conditions were presented pseudorandomly with no more than four consecutive repetitions of trial type or response.

828

829 *Supplementary Tables*

830 补充表 1 执行功能效应的计算方法


Executive Function Effect	Calculation Method	Reference
Stroop Interference Effect	RT Incongruent - RT Congruent	MacLeod (1991)
Go/No-go Inhibition Effect	Accuracy NoGo - Accuracy Go	Criaud & Boulinguez (2013)
Stop Signal Inhibition Effect	Stop Signal Reaction Time (SSRT)	Logan et al. (1984)
Task Switching Cost	RT Switch - RT Repeat	Schwarze et al. (2025)
Working Memory Updating Load Effect	Accuracy 750ms - Accuracy 1750ms	Wang et al. (2025)
	Accuracy 2back - Accuracy 0back	
	Accuracy 2back - Accuracy 1back	
	Accuracy 1back - Accuracy 0back	

Note: RT = Reaction Time; SSRT = Stop Signal Reaction Time, calculated using the integration method. Positive values indicate increased cognitive load or interference, while negative values indicate cognitive advantage. All indices were z-standardized within each dataset to ensure valid cross-task comparisons.

831


832

Supplementary Figures




补充图 1 执行功能范式流程图

注：本图为研究中使用的执行功能测量任务的实验流程。所有任务均记录参与者的按键反应数据。橙色标注为数据集 1 中的任务，绿色标注为数据集 2 中的任务。



补充图 2 重抽样分析的稳定性的验证

注：展示从人类总样本 ($N=1,970$) 中进行 3,000 次重复抽样 (每次 $N=120$) 的结果分布，用于验证主要发现的统计稳健性。



845

846 补充图 3 执行功能任务的分类框架

847 注：基于行为模式复现程度（横轴）和内部参数对应程度（纵轴）两个维度，将 8 项执行功能任务分为四
848 个象限，用于评估大语言模型在不同认知功能上的表现特征。

849

850

851

852

853 表 1 基于大语言模型问答认知（执行功能）任务

种子文献

文献	关注的认知成分	使用的模型	研究结果发现
(Coda-Forno et al., 2024)	"ten behavioral metrics derived from seven cognitive psychology experiments": 1) prior and likelihood weightings (probabilistic reasoning), 2) directed exploration and random exploration (horizon task), 3) meta-cognition (restless bandit), 4) learning rate and optimism bias (instrumental learning), 5) model-basedness (two-step task), 6) temporal discounting, 7) risk-taking (BART)	"35 LLMs", including "Anthropic's Claude-1 and Claude-2", "OpenAI's GPT-3 (text-davinci-003) and GPT-4", "Google's PaLM-2 for text (text-bison@002)", "Mosaic's MPT", "Falcon", "numerous LLaMA-2 variants"	"RLHF significantly increased meta-cognition" ($\beta=0.461\pm0.15$, $p<0.001$); "the number of parameters indeed had a significant influence on performance" ($\beta=0.277\pm0.39$, $p<0.001$) and "significant positive effect" on model-basedness ($\beta=0.481\pm0.22$, $p<0.001$); "proprietary models...are more likely to take risks" ($\beta=-0.612\pm0.11$, $p<0.001$); "11.7% average decrease in L2-Norm distance for models with RLHF"; "CoT showing an average increase of 9.01%" for probabilistic reasoning, "SB showed a substantial increase of 118.59%" for model-basedness
(Hu & Lewis, 2024)	"working memory", "task comprehension", "task set maintenance" - using "the n-back task"	"GPT 3.5 Turbo and open-source instruction-tuned models from the Qwen (Bai et al., 2023), Llama (Dubey et al., 2024), and Gemma (Team et al., 2024) families", specifically "Llama 3.1 70b Instruct (T1), Qwen 1.5 14b Chat (T3), and Gemma 2 27b	"T3: $\leq 20\%$ on 2- and 3-back", "T2: $\sim 50\%$ on 2-back; $\sim 40\%$ on 3-back", "T1: $> 80\%$ on 2- and 3-back"; "low-performing language models...commit errors that are consistent with a different m-back task ($m\neq n$)"; "intermediate models...tend to start with the correct task but drift toward a different one"; "High-performing models...consistently execute

		Instruct (T2)"	the correct task, even for larger n's, achieving task accuracies of 90.08%, 90.08%, and 84.75% for n=8,9,10"; "The T3 model fails to map 2-back and 3-back instructions to the correct responses"; "curriculum learning...leads to significant improvements in performance for larger n values"
(Gong et al., 2024)	"working memory", "working memory capacity", "verbal and spatial n-back tasks"	"ChatGPT (gpt-3.5-turbo)", "GPT-4", "Bloomz-7B, Bloomz-7B1-mt, ChatGLM-6B v1.0, ChatGLM-6B v1.1, Vicuna-7B, Vicuna-13B"	"ChatGPT has a working memory capacity limit strikingly similar to that of humans"; "Typical human performance drops significantly when n = 3"; "the model's d' drops to around 1 when n = 3"; "Adding noise significantly reduces the model's working memory capacity"; "CoT reasoning significantly improved model performance"; "GPT-4...possesses a working memory capacity that far exceeds that of other LLMs"; "other open-source LLMs...have a very low working memory capacity"
(Zhang et al., 2024)	"working memory", "world knowledge and logic" for reasoning, using "n-back benchmark" and "BBH set containing 23 tasks"	"text-ada-001 with 0.35B parameters to text-davinci-002 with 175B parameters", "text-davinci-001 and text-davinci-002", "ChatGPT", "GPT-3.5", "GPT-4"	"smaller models, such as text-curie-002...often show decreased accuracy with advanced prompts compared to basic answer-only prompts"; "larger models, beginning with text-davinci-001, exhibit significant performance improvements with advanced prompting strategies"; "text-ada-001 primarily engages in a basic, repetitive replication of the input QA structure"; "Text-davinci-002 demonstrates a superior ability to chunk information"; "code training in text-davinci-002...bolsters its internal reasoning"; "GPT-4, where d' scores in 1-back tasks in the 7×7 grid setting can rival or even surpass the human average"; "LLMs have not consistently surpassed human intelligence"
(Loconte et al., 2024)	"Verbal Reasoning", "Cognitive estimation", "Metaphors and idioms"	"GPT-3.5", "GPT-4", "Claude2", "Llama2"	"GPT-3.5 performed poorly" in absurdities subtest; GPT-3.5 achieved "severely impaired performance" in Tower of London (raw score "7 out

	comprehension", "Anaphoric referencing", "Planning", "Inhibition", "Insight", "Social cognition"		of 36"); "GPT-3.5 exhibited a raw score of 4 for Category A errors" in HSCT "which fall below the 5th percentile"; "GPT-4 performance fell in the normative human range for all the tasks included in the social cognition battery"; Claude2 showed "the same pattern of responses of GPT-3.5, except for the Intruders performance"; "Llama2 exhibited the worst pattern of responses with impaired performance in the total VRT score"
(Langis et al., 2025)	"Executive function" including "Cognitive Flexibility" (WCST), "Attentional Control" (Flanker Task); "Working & Short-term Memory" (Digit Span Tasks); "False/Gist Memory" (DRM Task)	"six open-source LLMs from three different model families": "Gemma2 with 9B and 27B parameters", "Llama3.1 with 8B and 70B parameters", "Qwen2 with 7B and 72B parameters", "All models are the instruction-tuned variants"	WCST: "All models tested have substantially lower accuracy than humans" (humans 70-80%); "models do not appear to do very well adapting to changing sorting rules"; "accuracy goes down across all models" with "significant negative correlations between dialogue length and accuracy"; Flanker: "Model performance is near perfect for the congruent letter strings, but has accuracy of around 40-60% for the incongruent letter strings" vs human "around 93% to 96%"; Digit Span: "all LLMs tested have nearly perfect responses for all digit lengths" in forward task with "forward digit span over 50 digits long"; "smaller models have decreased accuracy after 15-20 digits" in backward task; DRM: "larger LLMs have nearly perfect performance" and "are not susceptible to human-like false reports" (humans recognize unseen critical words 70% of the time); "bigger is not always better on these cognitive tasks"; "we find no consistently strong model: there is no 'winner' across all cognitive experiments"
(Cui et al., 2025)	Replicating "randomly selected experiments from top management and psychology journals through simulated	"GPT-4", "Claude", "DeepSeek"	"LLMs showing consistently larger effect sizes, narrower confidence intervals, and a strong tendency toward statistical significance"; "lower replication rates for management studies"; "GPT-4 showed moderate

	participant responses"		success in replicating interaction effects without the inflation bias seen in main effects"; "instances (1-2.5% of effects) where LLMs produced completely uniform responses across all simulated participants"; "GPT-4 exhibited this primarily in ethical scenarios, Claude and DeepSeek showed similar patterns across broader contexts"; "temperature adjustments had minimal impact on effect magnitudes or significance patterns" (ANOVA $F = 0.030$, $p = .971$); "different LLMs exhibit distinct patterns in handling socially sensitive topics such as race, gender, and ethics"
(Loconte et al., 2023)	"Verbal Reasoning Test (VRT)", "Cognitive Estimation Task (CET)", "metaphors and idioms comprehension", "anaphoric referencing", "planning abilities" using "Tower of London (ToL) task", "Hayling Sentence Completion test (HSCT)" for "inhibition", "Compound Remote Association (CRA) problems" for "creativity", "social cognition" including "Theory of Mind (ToM), Emotion Attribution, appropriateness of Social Situations, and Moral Judgments"	"ChatGPT"	VRT: "ChatGPT's performance on six out of seven subtests falls within the normal range"; "in the absurdities subtest, ChatGPT performed very poorly" with "score of 2 out of 14"; CET: "raw absolute error score of ChatGPT was 17/41, which corresponded to the 95th percentile"; "raw bizarreness score of 3/21, positioned in the normative range around the 75th - 85th percentiles"; "ChatGPT performed well in metaphors and idioms comprehension scoring 35/40 and 36/40"; anaphoric referencing "performance observed in ChatGPT was 16/20 within the range of elderly healthy controls (16-20)"; ToL: "raw score achieved by ChatGPT was 7 out of 36, which indicates a severely impaired performance" that "fell below the first percentile"; HSCT: "ChatGPT had a raw score of 3.5, which falls within the 63rd to 75th percentile"; CRA: "score achieved by ChatGPT was 21 out of 122 and fell in the 17.27th percentile when converted to a z-score ($z = -0.94$)"; social cognition: "ChatGPT performance fell in the normative human range for all the tasks included in the social cognition battery"

(Valmeekam et al., 2022)	"Thus, in this paper, we want to look at the ability of large language models to do reasoning about actions and change involving common-sense planning tasks." "Our focus on this specific task is spurred by not only the fact that reasoning about actions and change is a core aspect of human intelligence"	"While this paper reports the results of testing vanilla GPT-3, Instruct-GPT3 [20] and BLOOM [1]" "Our evaluation here primarily focuses on two Large Language Models, GPT-3 and BLOOM. In particular, we evaluated the test framework on the Blocksworld domain."	"The conclusion from our evaluation on GPT-3 and BLOOM is that LLMs are still far from achieving acceptable performance on common planning/reasoning tasks which pose no issues for humans to do." "Our results show that even in simple common-sense planning domains where humans could easily come up with plans, LLMs like GPT-3 and BLOOM seem to display a dismal performance."
--------------------------	---	--	---

854

855

