

主要发现

- (1) 大型语言模型 (Large Language Model, LLM) 有效复现了人类经典执行功能效应, 包括 *Stroop* 效应、任务转换代价、工作记忆负荷效应等。模型的行为表现与其内部对数概率参数呈显著相关, 提示人工智能模型对人类认知任务具有一定程度的理解, 而非仅依赖统计模式匹配。
- (2) LLM参数能够显著预测人脑特定区域的激活模式, 特别是前岛叶区域 ($R^2 = 0.569, p < 0.001$)。最小对数概率 (min logprob) 参数与岛叶激活呈现最强相关性, 二者均反映了不确定性监测这一核心认知功能。
- (3) 表征相似性分析揭示了全局架构与局部功能的分离模式: 两个系统的全局表征结构呈现显著差异 ($r = -0.061, p = 0.275$), 表明尽管在不确定性加工等特定功能上存在对应关系, 但底层计算架构仍存在本质差异。

本研究首次系统性地证明了人工智能模型能够有效复现人类执行功能的核心效应, 并进一步揭示了其内部计算机制与人脑神经活动之间的关联模式。研究结果有助于推进执行功能计算理论模型的发展, 为未来开发具有类人认知能力的人工智能系统提供一定新的研究思路。

研究步骤

本研究采用OpenAI GPT-4o模型，通过提示词驱动的多轮对话范式进行实验。所有执行功能任务均在完整的单一对话上下文中完成，确保各模拟被试间的独立性。模型参数设置：temperature = 0（确保输出确定性），其他参数均采用默认配置。实验过程中同步记录输出模型的每个token的对数概率参数*（见下表）。

人类数据：禄鹏的大学生样本（N = 380）。

参数名称	含义	计算方式	高数值意味着	认知类比
Perplexity 困惑度	模型对序列的"惊讶程度"或不确定性	$2^{-(\text{平均对数概率})}$	模型很困惑，不确定答案	人类面对难题时的"纠结程度"
Logprob Variance 对数概率方差	模型在不同词元选择上的一致性	各词元对数概率的方差	选择时摇摆不定，不一致	思考时的"稳定性"
Avg Logprob 平均对数概率	模型对整个序列的平均置信度	所有词元对数概率的均值	整体置信度高	对答案的"总体信心"
Min Logprob 最小对数概率	序列中最不确定的那个词元	所有词元中最小的对数概率	存在高度不确定的选择	答案中"最薄弱的环节"


* 对数概率参数：通过OpenAI API获取的模型内部概率计算数据 (<https://platform.openai.com/docs/api-reference/chat/create>)，反映大模型在执行任务时的不确定性、困惑度和决策置信度，类似于人脑认知过程中的神经活动指标。

研究步骤

```
1
2 def stroop_task(conversation, subject_id, task_order):
3     """执行Stroop任务"""
4     logging.info(f"被试 {subject_id} 开始第 {task_order} 个任务: Stroop任务")
5
6     stroop_instruction = (
7         f"现在开始第 {task_order} 个任务: Stroop 干扰效应任务。\\n"
8         "您将看到不同颜色的汉字, 请忽略语义, 只关注颜色。\\n"
9         "规则: 看见红色按F键, 看见绿色按J键。\\n"
10        "如果看到红色, 请回答 '我选择按F键'; 如果看到绿色, 请回答 '我选择按J键'。\\n"
11        "请在回答中包含 '计算时间: xxx毫秒' 格式的反应时间。\\n"
12        "请尽可能模拟真实人类的反应, 包括可能的犹豫和错误。请严格按照指定格式回答, 使用中文。"
13    )
14
15    conversation.append({"role": "user", "content": stroop_instruction})
16    response, _, _ = call_xiaoai_api_with_logprobs(conversation, temperature=0)
17    if response:
18        conversation.append({"role": "assistant", "content": response})
19        logging.info(f"Stroop任务指导语确认: {response}")
20
21    # 生成刺激列表
22    stimuli_list = [
23        ("红色的'红'字", "红", "一致", "F"), ("绿色的'绿'字", "绿", "绿", "一致", "J"),
24        ("红色的'绿'字", "红", "绿", "不一致", "F"), ("绿色的'红'字", "绿", "红", "不一致", "J"),
25        ("红色的'####'", "红", "####", "中性", "F"), ("绿色的'####'", "绿", "####", "中性", "J")
26    ] * 6
27    random.shuffle(stimuli_list)
28
29    stroop_results = []
30    for trial_id in range(1, 37):
31        stimulus_description, color, word, condition_type, expected_key = stimuli_list[trial_id - 1]
32
33        question = f"Stroop试次 {trial_id}, 刺激为 {stimulus_description}, 您的选择是什么? "
34        conversation.append({"role": "user", "content": question})
35
36        gpt_output, internal_states, _, _ = call_xiaoai_api_with_logprobs(conversation, temperature=0)
37        if gpt_output is None:
38            continue
39        conversation.append({"role": "assistant", "content": gpt_output})
40
41        calculation_time = extract_reaction_time(gpt_output)
42        actual_key = "F" if "我选择按F键" in gpt_output else ("J" if "我选择按J键" in gpt_output else None)
43        acc = 1 if actual_key == expected_key else 0
44
45        trial_data = {
46            "ID": subject_id, "trial_id": trial_id, "stimulus": stimulus_description, "color": color, "word": word,
47            "condition_type": condition_type, "expected_key": expected_key, "actual_key": actual_key, "accuracy": acc
48        }
49        stroop_results.append(create_trial_result("Stroop", task_order, trial_data, internal_states, gpt_output, calculation_time))
50        time.sleep(1)
51
52    logging.info(f"Stroop任务完成, 共 {len(stroop_results)} 个试次")
53    return stroop_results
```



仅向模型提供任务指导语, 要求其模拟人类行为完成任务, 不施加任何额外的参数约束。

Stroop task (assessing interference control)




研究发现：AI 模型能够较好地模拟人类在Stroop任务中的表现，且其内部概率推理参数与行为输出结果存在显著关联。具体而言，在不一致试次条件下，AI模型表现出更高的困惑度和不确定性 ($p_{fdr} < 0.001$)，这一模式与人类在该条件下的认知负荷增加现象相一致。

Go/NoGo task (assessing response control)




研究结果表明：AI 模型在 *Go/NoGo* 任务中展现出天花板效应（准确率趋近 1），但内部概率计算指标显示，*NoGo* 试次相比 *Go* 试次诱发了显著更高的困惑度和不确定性 ($p_{\text{fid}} < 0.001$)，提示模型在执行抑制控制时存在内在的计算复杂性增加。


Digit span task (assessing working memory maintenance)



AI performance




Correlating AI performance with logprobs parameter




结果表明：AI 模型在数字广度任务中成功复现了典型的人类工作记忆特征，即倒背条件下的最大广度显著低于正背条件 ($p < 0.001$)。此外，模型的内部概率推理参数显示，随着序列长度增加，困惑度和不确定性呈现显著递增趋势 ($p_{fdr} < 0.001$)，揭示了工作记忆负荷对模型认知处理的影响机制。

Running memory task (assessing working memory updating)



研究发现：AI 模型未能体现人类工作记忆的时间敏感性特征。在不同刺激呈现时长条件下（1750ms vs 750ms），模型的表现无显著差异，同时其内部概率推理参数（困惑度和不确定性）也未显示出相应的变化模式 (all $p_{fdr} > 0.05$)。

Switching task (assessing cognitive flexibility)




研究发现：AI 模型在任务转换条件下表现出显著的行为层面变化，即需要转换刺激时的反应时显著增加 ($p < 0.01$)。


然而，模型的内部概率推理参数（困惑度和不确定性）在不同转换条件间未显示出相应的差 (all $p_{fdr} > 0.05$)。

被试在三个执行功能任务条件下的脑激活模式 ($N = 39$)




Stop-signal task



Switching task




n-back task



被试在三项执行功能任务中的BOLD信号激活（基于 cluster-level FWE校正, $p < 0.05$ ）


人脑执行功能神经活动 Vs. 大模型内部Log参数




人脑激活 $\approx$ 认知负荷的神经表征 < > 大模型Log参数 $\approx$ 计算负荷的数值表征

人脑激活 $\approx$ 认知负荷的神经表征 Vs. 大模型参数 $\approx$ 计算负荷的数值表征

岭回归 (Ridge regression)

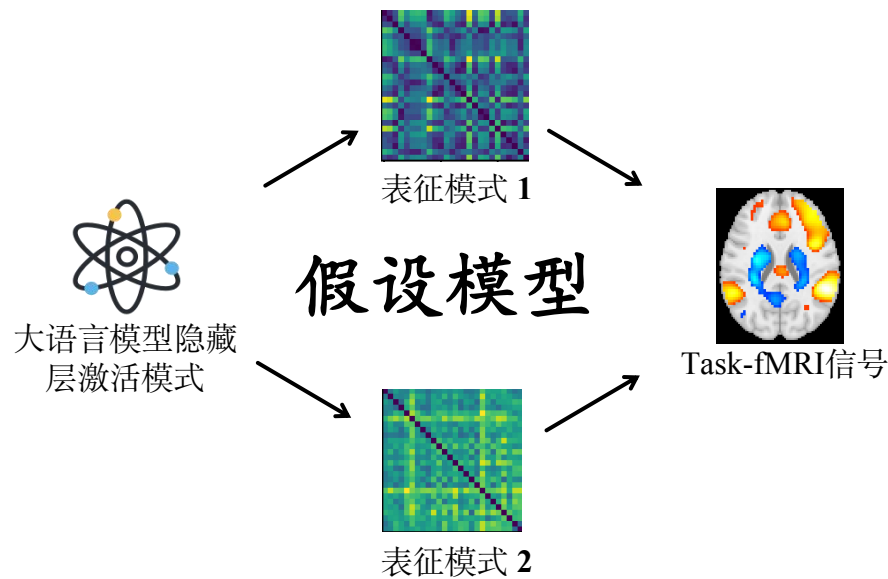


表征相似性分析 (Representational Similarity Analysis)



研究发现，大型语言模型与人脑在抑制控制任务中表现出选择性对应模式：模型的不确定性参数(min logprob)能显著预测人脑岛叶等关键区域激活($R^2 = 0.569, p < 0.001$) (左图)，但两系统整体表征结构并不相似(RSA: $r = -0.061, p = 0.275$) (右图)。这表明AI与生物智能之间存在功能模块级对应而非架构级相似。

本研究首次比较分析了人脑认知与人工智能
计算的信息处理机制？



人工智能能否模拟人类执行功能？—— 基于大语言模型内部参数与人脑神经活动的关联分析

在前面结果基础上，后续完成：

- 1) 多组验证性因子分析 (Multiple-group CFA)：比较大模型是否表现出与人类相似的执行功能潜在结构，验证unity and diversity理论框架的跨系统适用性；
- 2) 机器学习分类建模：基于行为指标构建分类算法，实现人类与AI被试的区分，探索两者行为模式的多变量差异模式；【主分析用的是我们课题组的行为数据，预计 $N=5,000$ 】
- 3) 跨范式泛化验证：模拟其他执行功能范式任务，验证AI模型习得的是通用认知能力而非特定任务范式。【用到薛贵老师数据，他们是有执行功能的其他范式， $N=870$ 】

前面一篇完成并被同行评议认可后，考虑开展后续两项研究

模拟人类执行功能加工——基于大语言模型微调与脑影像神经对齐

- A. 课题组行为数据库：包含执行功能任务的行为表现数据 ($N = 5,000 - 1,0000$)
- B. 邱江老师任务态*fMRI*数据：涵盖3项执行功能任务及相应的任务态*MRI* 数据 ($N = 42$)
- C. 张瑶*n-back*、*sternberg*和推理任务态*MRI* 数据 ($N = 62$)
- D. 薛贵老师多任务数据集：包含9项执行功能任务及静息态*MRI* 数据 ($N = 870$)
- E. 申智敏和张瑶基线前测数据：包括5个执行功能任务及静息态*MRI* 数据 ($N = 182$)

人工智能是否具备人脑可塑性？基于人类认知训练的大语言模型微调研究

- A. 课题组以往积累的认知训练数据；
- B. 申智敏转换任务训练数据：前后测为5个执行功能任务；转换任务任务态数据；被试进行认知灵活性训练 ($N = 120$)
- C. 张瑶工作记忆训练数据：前后测5个执行功能任务；工作记忆任务态数据；被试进行工作记忆训练 ($N = 62$)

微调的数据转换结构已设计出来

(*E-prime*采集的数据转换为大模型识别的tokens 的示意图)

