

主要发现

- (1) 大型语言模型 (Large Language model, LLM) 有效复现了人类经典执行功能效应, 包括 *Stroop* 效应、转换代价、工作记忆负荷等, 并且模型输出表现与内部对数概率参数显著相关, 提示人工智能模型已对人类认知任务具备一定理解, 而非通过统计学模式匹配。
- (2) LLM 参数显著预测人脑特定区域激活, 尤其是前岛叶 ($R^2 = 0.569, p < 0.001$); `min_logprob` 参数与岛叶激活最强相关, 二者共同反映不确定性监测这一核心认知功能。
- (3) 表征相似性分析揭示全局架构与局部功能的分离: 两系统全局表征结构显著不相似 ($r = -0.061, p = 0.275$), 表明尽管在不确定性加工等局部功能上存在对应, 但底层计算架构存在根本性差异。

本研究首次证明了人工智能模型能够有效复现人类执行功能的核心效应, 并进一步揭示了其内部计算机制及其与人脑神经活动的关联。

当前问答这篇文章研究的单变量行为结果

本研究采用OpenAI GPT-4o模型，通过提示词驱动的多轮对话范式进行实验。所有执行功能任务均在完整的单一对话上下文中完成，确保各模拟被试间的独立性。模型参数设置：temperature = 0（确保输出确定性），其他参数均采用默认配置。实验过程中同步记录输出模型的每个token的对数概率参数*（详见下表）。


人类数据：禄鹏的大学生样本（N = 380）。

参数名称	含义	计算方式	高数值意味着	认知类比
Perplexity 困惑度	模型对序列的"惊讶程度"或不确定性	$2^{(-\text{平均对数概率})}$	模型很困惑，不确定答案	人类面对难题时的"纠结程度"
Logprob Variance 对数概率方差	模型在不同词元选择上的一致性	各词元对数概率的方差	选择时摇摆不定，不一致	思考时的"稳定性"
Avg Logprob 平均对数概率	模型对整个序列的平均置信度	所有词元对数概率的均值	整体置信度高	对答案的"总体信心"
Min Logprob 最小对数概率	序列中最不确定的那个词元	所有词元中最小的对数概率	存在高度不确定的选择	答案中"最薄弱的环节"


* 对数概率参数：通过OpenAI API获取的模型内部概率计算数据 (<https://platform.openai.com/docs/api-reference/chat/create>)，反映模型在执行任务时的不确定性、困惑度和决策置信度，类似于人脑认知过程中的神经活动指标。

Stroop task (assessing interference control)


Human performance



AI performance




Correlating AI performance with logprobs parameter



研究发现：AI 模型能够较好地模拟人类在Stroop任务中的表现，且其内部概率推理参数与行为输出结果存在显著关联。具体而言，在不一致试次条件下，AI模型表现出更高的困惑度和不确定性，这一模式与人类在该条件下的认知负荷增加现象相一致。


Go/NoGo task (assessing response control)




研究结果表明：AI 模型在Go/NoGo任务中展现出天花板效应（准确率趋近1），但内部概率计算指标显示，NoGo试次相比Go试次诱发了显著更高的困惑度和不确定性，提示模型在执行抑制控制时存在内在的计算复杂性增加。

Digit span task (assessing working memory maintenance)


Human performance



AI performance




Correlating AI performance with logprobs parameter



结果表明：AI 模型在数字广度任务中成功复现了典型的人类工作记忆特征，即倒背条件下的最大广度显著低于正背条件。此外，模型的内部概率推理参数显示，随着序列长度增加，困惑度和不确定性呈现显著递增趋势，揭示了工作记忆负荷对模型认知处理的影响机制。





Running memory task (assessing working memory updating)






研究发现：AI 模型未能体现人类工作记忆的时间敏感性特征。在不同刺激呈现时长条件下（1750ms vs 750ms），模型的表现无显著差异，同时其内部概率推理参数（困惑度和不确定性）也未显示出相应的变化模式。

Switching task (assessing cognitive flexibility)

Human performance




AI performance




研究发现：AI 模型在任务转换条件下表现出显著的行为层面变化，即需要转换刺激时的反应时显著增加。然而，模型的内部概率推理参数（困惑度和不确定性）在不同转换条件间未显示出相应的差。

被试在三个执行功能任务条件下的脑激活模式 ($N = 39$)




Stop-signal task






Switching task



n-back task







人脑激活 $\approx$ 认知负荷的神经表征 Vs. 大模型参数 $\approx$ 计算负荷的数值表征



人脑激活 $\approx$ 认知负荷的神经表征


大模型参数 $\approx$ 计算负荷的数值表征




● Congruent ● Incongruent ● Neutral

人脑激活 $\approx$ 认知负荷的神经表征 Vs. 大模型参数 $\approx$ 计算负荷的数值表征

Human ROI



AI logprobs parameters



Stop 条件减去 Go 条件
2back 减去 0back


....

人脑 ---> 激活差值


大模型 ---> Log 参数差值

人脑激活 $\approx$ 认知负荷的神经表征 Vs. 大模型参数 $\approx$ 计算负荷的数值表征

岭回归 (Ridge regression)




表征相似性分析 (Representational Similarity Analysis)



研究发现, 大型语言模型与人脑在抑制控制任务中表现出选择性对应模式: 模型的不确定性参数(min logprob)能显著预测人脑岛叶等关键区域激活($R^2 = 0.569, p < 0.001$) (左图), 但两系统整体表征结构并不相似(RSA: $r = -0.061, p = 0.275$) (右图)。这表明AI与生物智能之间存在功能模块级对应而非架构级相似。

本研究首次探究人脑认知与人工智能计算是否
遵循相似的信息处理原理？



人工智能能否模拟人类执行功能? —— 基于大语言模型内部参数与人脑神经活动的关联分析

在前面行为结果基础上, 后续完成:

- 1) 多组验证性因子分析 (Multiple-group CFA) : 比较大模型是否表现出与人类相似的执行功能潜在结构, 验证unity and diversity理论框架的跨系统适用性;
- 2) 机器学习分类建模: 基于行为指标构建分类算法, 实现人类与AI被试的自动区分, 探索两者行为模式的多变量差异模式; 【主分析用的是我们课题组的行为数据, 预计 $N=5,000$ 】
- 4) 跨范式泛化验证: 模拟其他执行功能范式任务, 验证AI模型习得的是通用认知能力而非特定任务范式。【用到薛贵老师数据, 他们是有执行功能的其他范式, $N=870$ 】
- 3) 神经-计算关联分析: 提取人脑执行功能相关激活模式, 与大模型内部概率参数进行关联性分析, 揭示生物与人工智能的认知计算对应关系。【用到邱江老师文章的任务态fMRI (task-fMRI) , $N=39$ 】
- 4) 张瑶基线前测工作记忆任务态数据 【 $N=62$ 】

模拟人类执行功能——基于大语言模型微调与脑影像神经对齐

- A. 课题组行为数据库：包含执行功能任务的行为表现数据 ($N = 5,000-8,000$)
- B. 邱江老师任务态fMRI数据：涵盖3项执行功能任务及相应的任务态MRI数据 ($N = 42$)
- C. 张瑶n-back、sternberg和推理任务态MRI数据 ($N = 62$)
- D. 薛贵老师多任务数据集：包含9项执行功能任务及静息态MRI数据 ($N = 870$)
- E. 申智敏和张瑶基线前测数据：包括5个执行功能任务及静息态MRI数据 ($N = 182$)

人工智能是否具备人脑可塑性？基于人类认知训练的大语言模型微调研究

- A. 课题组以往积累的认知训练数据；
- B. 申智敏转换任务训练数据：前后测为5个执行功能任务；转换任务任务态数据；被试进行认知灵活性训练 ($N = 120$)
- C. 张瑶工作记忆训练数据：前后测5个执行功能任务；工作记忆任务态数据；被试进行工作记忆训练 ($N = 62$)

微调的数据转换结构已设计出来

(*E-prime*采集的数据转换为大模型识别的*tokens*)

